密　级：公开

| | |
|---|---|
| 技术领域 | 请填写技术领域编号，如：CALT2022-18 |

# 一院高校联合创新基金项目

# 申 请 书

项目名称：

申请单位：

申 请 人：

通信地址：

邮政编码：

电　　话：

申请日期：

中国运载火箭技术研究院

二〇二二年

# 填 报 说 明

一、申请书各项内容要实事求是，逐条逐项认真填写。不符合规定者，将不予受理。

二、项目研究周期为一年。

三、申请书采用 A4 纸双面打印，左侧装订成册。一级标题用四号黑体，无缩进；其余标题和正文用四号仿宋体，首行缩进二字符。

四、“项目名称”应确切反映研究内容，最多不超过 25 个汉字（包括标点符号）。申请书主要内容部分应具体、翔实。

五、封面上的“研究方向”一栏，由申请单位对照 CALT 基金重点支持的研究方向，准确填写技术方向的编号。

六、“应用单位意见”需由应用单位主管领导签字，并加盖厂所级公章；“学校审查意见”需由本校领导审查签字，并加盖学校公章。

# 项目申请基本信息表

<table>
<tr><td colspan="2">项 目 名 称</td><td colspan="8">空间机器人在轨操作技能智能学习技术研究</td></tr>
<tr><td rowspan="2">申请者</td><td>姓　名</td><td></td><td>性别</td><td></td><td>年龄</td><td></td><td>学位</td><td colspan="2"></td></tr>
<tr><td>职　称</td><td></td><td>专业特长</td><td colspan="3"></td><td>联系电话</td><td colspan="2"></td></tr>
<tr><td rowspan="2">工作单位</td><td>名称</td><td colspan="8"></td></tr>
<tr><td>主管部门</td><td colspan="3"></td><td>合作单位</td><td colspan="4"></td></tr>
<tr><td colspan="2">项目基本情况概述<br>（100 字左右）</td><td colspan="8">针对空间机械臂在轨高精度操作任务对自主操作技术的迫切需求，研究空间机械臂的视/力多源信息融合的自主操作技术、基于 DRL 的复杂操作学习技术、技能的高效获取与迁移等关键技术，开展模拟空间环境下的在轨高精度插拔智能学习技术试验，完成关键技术验证。</td></tr>
<tr><td colspan="2">项目技术难度或创新点<br>（100 字左右）</td><td colspan="8">针对传统空间机械臂控制算法难以解决的存在丰富接触碰撞的高精度插拔任务，研究基于深度强化学习的高精度视/力融合插拔操作技能学习。针对操作技能学习困难、学习效率低的问题，提出结合启发式控制策略的残差深度强化学习算法。针对操作技能难以在相似任务上迁移的问题，提出将元强化学习与域随机化技术相结合的技能迁移算法。</td></tr>
<tr><td colspan="2">预期成果<br>（括号中划√）</td><td colspan="8">A．集成演示系统（　） B．工艺（　） C．装备（　）<br>D．样机（　） E．样品（　） F．软件（√ ）<br>G．论文（　） H．专利（　）</td></tr>
<tr><td colspan="2">主题词</td><td colspan="8">空间机械臂，高精度插拔，深度强化学习，技能迁移，元强化学习，域随机化</td></tr>
</table>

## 一、需求分析

空间机械臂在空间站建造、在轨组装、在轨维修等任务中发挥着重要作用。随着在轨操作向着大规模、高精度发展，提出了如空间太阳能电站建造、大型空间望远镜建造等复杂任务，对空间机械臂的能力要求极高。然而目前空间机械臂的控制模式仍以遥操作和人工示教为主，自动化程度十分有限，在复杂的大规模在轨操作任务中难以满足需求。一方面，随着任务量的增大需要投入大量的人力对空间机械臂进行遥操作或示教，影响在轨操作的效率。另一方面，由于空间机械臂自身的结构精度和控制精度的限制以及力反馈的误差和通讯时延的影响，**当涉及高精度的手眼协调操作时，如空间机械臂在轨操作任务中典型的高精度插拔操作，遥操作和示教都难以保证任务的成功。综上所述，空间机械臂亟需自动的手眼协同高精度操作能力。**

随着人工智能尤其是强化学习的发展，赋予了机器人强大的学习能力，也为机器人领域带来了新的机遇。强化学习是机器人与环境不断交互，进而不断强化自身决策能力的过程，深度学习与强化学习结合形成的深度强化学习则进一步提升了机器人对高维传感器数据的处理能力。**借助深度强化学习技术，机器人可以直接根据图像、力矩、触觉等多源感知信息进行端到端的控制，为实现高精度手眼协同操作提供了可行的技术途径。**

基于深度强化学习的地面机械臂精确操作已经得到了广泛的研究，实现了如轴孔装配、复杂零件组装等需要结合力觉和视觉的精细操作任务。但目前的研究需要大量的真实机械臂操作数据进行训练，同时存在相似任务之间迁移能力差的问题，而空间机械臂太空工作环境的特殊性导致无法提供大量的实际操作数据。**综上所述，需要结合典型的空间机械臂高精度插拔操作任务，建立高拟真度的空间机械臂插拔操作仿真训练场景，在此基础上研究空间机器人的高效技能训练方法以及从仿真到真实场景的迁移技术和相似场景之间的适应技术。**

## 二、国内外研究现状

### （一）基于深度强化学习的机械臂精确操作研究现状

近年来，具有自主学习能力的智能控制系统取得了显著进展，强化学习已被广泛用于解决复杂的接触密集的装配任务。强化学习的核心思想是使机器人主动学习和探索装配策略，通过奖励机制给出高级指导，而不是明确地指定具体的动作。通过接触模型识别和柔性控制过程的平滑结合，机器人可以通过与环境的交互实现增量学习。强化学习的最新进展在解决机器人操作问题方面取得了巨大的成功，特别是与用于参数化策略函数和价值函数的深度神经网络(DNNs)相结合。**根据机器人与环境之间的交互过程中是否存在学习到的模型，强化学习方法通常分为无模型和基于模型两大类。近年来，基于模型和无模型技术的结合也引起了相当大的关注。**

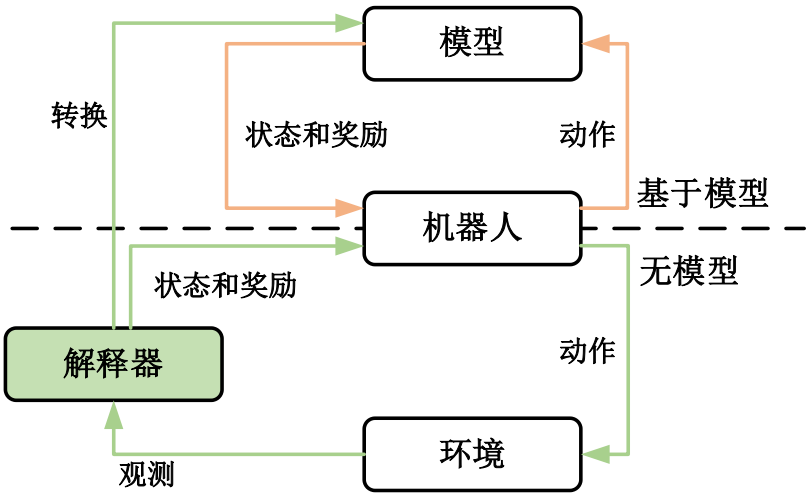



图 1 基于模型的强化学习与无模型的强化学习

1. 无模型强化学习

无模型强化学习方法在探索状态-动作空间的同时估计一个动态的环境模型来学习最优策略。**解决无模型强化学习问题的方法可以分解为两种:基于值的方法和基于策略的方法。**1992 年，首次提出了一种基于值的强化学习方法，通过神经网络来学习值函数，并采用 E-greedy 方式选择离散装配动作。2017 年，提出了一种利用长短时记忆(LSTM)网络估计值函数的学习算法，实现了轴孔装配精度超过机器人自身精度的控制。另一个用于解决实际机器人装配问

题的学习框架是:将强化学习控制系统的输出作为底层基于位置的力控制器的参数，而不是直接控制机器人。

**基于值的方法的局限性在于强化学习系统的输出动作只能是离散的、低维的。**基于策略的方法在高柔顺机器人应用中得到了广泛的探索。提出了由行动者和批评者两个组件实现的 RL 方法，行动者用于获得装配策略，批评者用于评估行为。随着基于政策的方法的发展，提出了确定性政策梯度(deterministic policy gradient, DPG)理论，以实现高稳定性的差异化政策学习。随后，深度确定性策略梯度(deep deterministic policy gradient, DDPG)方法与 DNNs 结合开发出来，这些方法被广泛应用于高维连续动作控制应用。

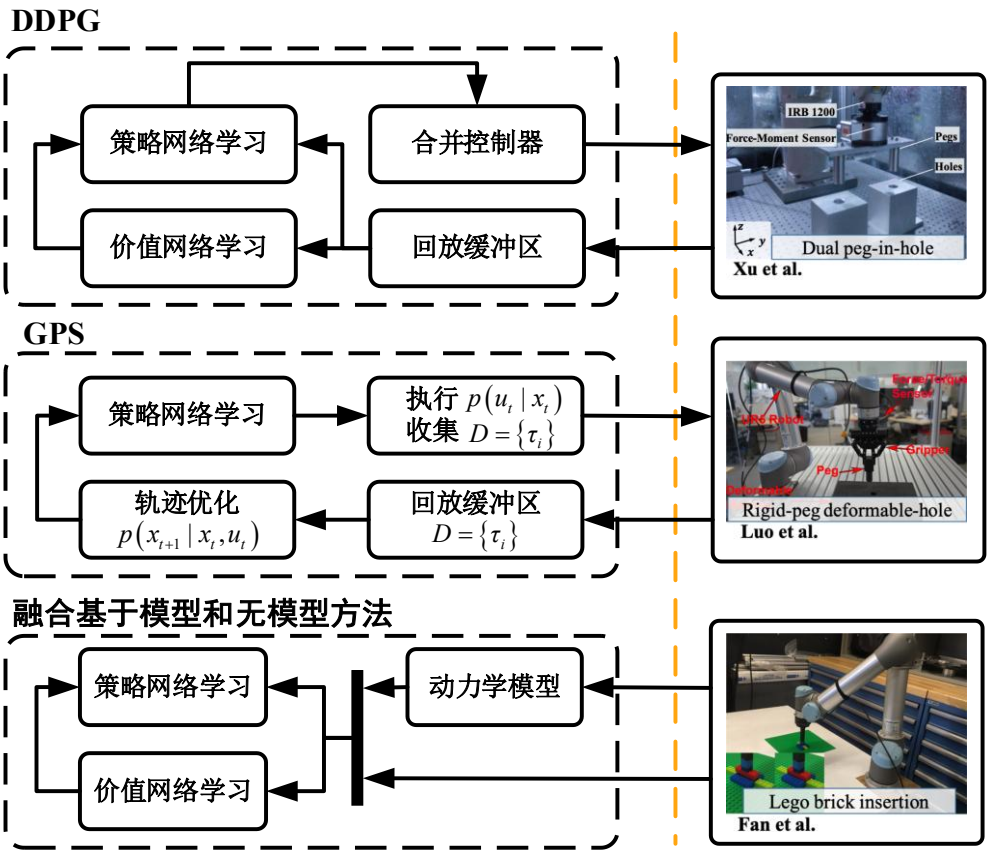



图 2 深度强化学习在机器人精确操作领域的应用实例

**基于策略的方法适用于解决具有连续和高维动作的现实问题。**参数化策略的学习总是收敛缓慢，具有高度的方差和不稳定性。到目前为止，已经有一些关于提高实际机器人装配中 DDPG 框架的稳定性和效率的研究发表，这些研究允许从不同的样本分布中学习，DDPG 算法已用于学习多孔装配问题的通

用装配策略。此外，许多研究集中在整合先验知识以提高效率，如结合演示的DDPG (DDPGfD)方法，将人类演示输入到专家记忆缓冲区中，通过优先重放机制重用该缓冲区来增强策略学习。与为机器人提供基线策略不同，很多学者研究利用装配件几何信息的先验知识来规划机器人的运动轨迹，这些作者专注于利用计算机辅助设计(CAD)的几何信息进行装配运动规划，并利用强化学习算法处理环境的动力学。

2. 基于模型的强化学习

与典型的无模型的强化学习方法相比，基于模型的 RL 方法旨在从存储的状态转移数据中学习一个动力学模型，并通过从学习到的模型中获取奖励和下一个状态来优化策略。对于复杂的操纵任务，通过与学习的动力学模型直接交互来导出最优策略的策略搜索方法具有较快的收敛速度。如引导策略搜索(GPS)方法，该方法结合了轨迹优化组件和神经网络策略学习组件。在 GPS 方法的基础上，提出了镜像下降 GPS (MDGPS)来解决复杂的装配任务，使用非柔顺机器人和外部 F/T 传感器，用于刚性销和可变形孔的装配。概率学习控制推理(PILCO)框架采用高斯过程(Gaussian Process)对过渡动力学建模，用线性函数表示策略，该框架在样本效率和时间效率方面是最先进的基于模型的 RL 算法。

**基于模型的 RL 方法只需要探索比无模型方法更狭窄的空间，从而在与环境的交互较少的情况下更快地收敛。然而，基于模型的 RL 方法的性能很大程度上取决于学习到的动力学模型的准确性。**

3. 基于模型和无模型方法的融合

无模型和基于模型的 RL 方法各有优缺点。无模型 RL 方法能够以一种通用的、简单的实现方式突出地解决复杂的装配问题，但效率较低。基于 DDPG 的无模型算法可以提供更稳定的策略，并在某些装配任务中获得超过非光滑动力学模型性能的渐近性能。基于模型的策略学习方法能够利用丰富的经验信息来增强策略学习。此外，基于模型的最优控制器将探索空间限制在一个安全区

域，但由于模型偏差较大，往往不能始终保持良好的收敛性能。近年来，将基于模型和无模型的 RL 方法的优点相结合已经成为研究的热点。**大部分的工作集中在从基于模型学习到政策学习的平滑过渡，并从交互数据中获得更多有用的信息。**

**（二）小样本数据下的机械臂深度强化学习**

基于强化学习的机器人操作技能学习方法需要大量的训练数据，使用少量训练数据就可学习到新的操作技能成为了机器人快速应用于各领域的关键。**近年来发展的迁移学习（Transfer learning）和元学习(Meta learning)具有利用先前数据经验的机制，在面对新任务少量数据时，能够实现基于小样本数据的快速任务学习。**

1. 迁移学习

迁移学习是从一个或多个源域（Source domain）中抽取知识、经验，然后应用予目标域（Target domain）的学习方法。在诸如计算机视觉及控制等领域取得了一定的进展。在机器人操作技能学习领域，迁移学习可将基于一种或多种任务上学习到的能力迁移到另一种新的任务上，以提高机器人操作技能的学习效率。机器人操作技能学习中的迁移学习主要包含两个方面：**1）基于环境，将虚拟环境中学习到的操作技能迁移到真实环境中；2）基于任务，将在一种任务上学习到的操作技能迁移到另一种任务上。**

在仿真环境中，机器人操作技能学习的训练成本低廉，并可避免使用真实机器人训练所带来的诸多不便性和危险性。但由于仿真环境与机器人真实工作场景不一导致仿真环境中学习到的操作技能策略在真实环境中表现效果欠佳，为此如何将虚拟环境中学习到的策略较好地应用于真实环境是机器人操作技能学习研究的关键问题之一。**域随机化（Domain randomization）技术**针对上述问题而提出，通过在模拟环境中改变物体的纹理、光照以及相机的位置等条件对神经网络进行训练，之后不需额外数据训练即可将在虚拟环境中训练得到的策略直接座用到真实环境中。

通过基于一种或多种任务学习的技能策略初始化新任务技能策略，可加快机器人对新任务操作技能策略的学习效率，如通过构建多个机器人之间共有的特征空间，采用多任务学习的形式在虚拟仿真环境中实现了将 3 连杆机器人抓取、移动指定物体的操作技能通过少量数据迁移给 4 连杆机器人的目标。

2. 元学习

机器人的迁移学习在一定程度上可提高机器人学习操作技能的 效率，然而在面对新任务时，仍然需要以机器人与环境进行一定的交互为前提，即仍然不能使机器人通过一次或极少次示教数据成功学习新的操作技能。

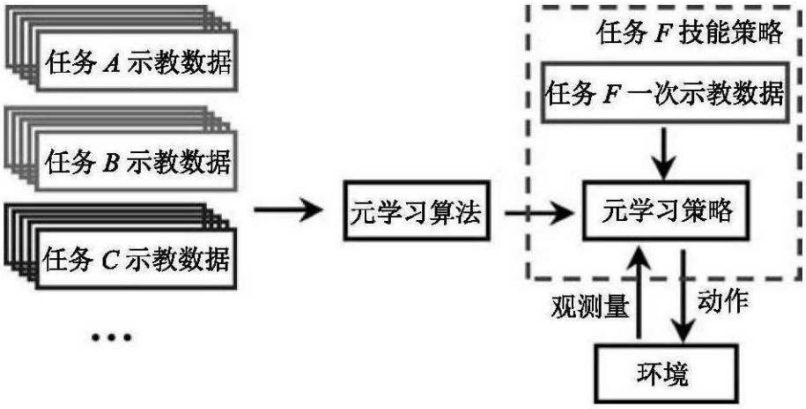



图 3 一次性模仿学习示意图

元学习及以此为基础的一次性学习（One-shot learning）是一种基于少量训练数据对模型进行学习的机器学习方法。元学习通过在大量相关任务且每种任务包含少量标记数据的任务集上对策略进行训练，能够自动学得训练任务集中的共有知识。在机器人操作技能学习领域，提出了一次性模仿学习方法，基于多种任务采用元学习算法训练得到元学习策略，学习完成后基于新任务的一次示教就可完成执行新任务的操作技能。

把元学习运用到强化学习领域的方法统称元强化学习（Meta reinforcement learning，Meta RL），其目的是自动从一组相关任务中学习有益的归纳偏置，为后续强化学习服务。由于目前深度强化学习算法在现实应用中普遍面临样本效率低、学习速度慢和泛化能力低（每个新任务需重新训练）的性能瓶颈，元强化学习算法通过试图自动为深度强化学习任务提供有益偏置的方法，为上述

问题的解决指出了一条有希望的途径。一个元强化学习算法主要包含 3 个元素：学习经验（相关任务）、归纳偏置及学习目标。算法首先在相关任务上进行元学习，自动抽取这些任务背后的共同模式，即归纳偏置，然后将其应用于具体的强化学习算法。**简而言之，元强化学习的核心在于如何有效地发现、表示和重用相关任务背后共同的知识，使得新的强化学习任务不必每次从头开始学习。**

**（三）总结**

机械臂精确插拔操作可以利用基于模型或无模型的深度强化学习算法来实现。基于模型的深度强化学习算法收敛速度快、需要的交互数据少，可以直接在真实机械臂上进行训练，但训练的结果受模型的影响较大，受限于模型偏差。无模型的深度强化学习算法容易实现、不需要环境的先验知识，但需要大量的训练数据不适合在真实机械臂上进行训练。考虑到仿真环境与真实机械臂工作环境不可避免存在偏差，因此无模型强化学习算法需要研究如何实现仿真环境中训练得到的模型向真实机械臂的迁移。此外，无论是基于模型的深度强化学习算法还是无模型的深度强化学习算法都存在操作技能在相似任务之间的泛化问题，元学习是解决此问题的重要途径。元学习通过在大量相关任务集上对策略进行训练，能够自动学得训练任务集中的共有知识，借此实现在同类新任务上的快速学习，只需要极少量的交互即可学习。综上所述，可以得出如下结论：

**1. 无模型强化学习技术需要利用仿真训练场景获取大量交互数据，当具有高拟真度的仿真训练环境时，无模型的深度强化学习算法更有优势。**

**2. 仿真环境与真实机械臂工作环境不可避免存在偏差，迁移学习中的域随机化技术可以在一定程度上解决仿真环境与真实环境之间的差异问题。**

**3. 深度强化学习算法对任务的变化非常敏感，元学习可以解决操作技能在相似任务之间的快速泛化问题。**

## 三、研究目标、研究内容与技术指标

### （一）研究目标

由于空间机械臂自身的结构精度和控制精度的限制以及力反馈的误差和通讯时延的影响，遥操作和示教控制都难以实现涉及丰富接触碰撞的高精度插拔操作。针对空间机械臂手眼协同高精度操作的迫切需求，以高精度插拔任务为关注点，研究基于深度强化学习的空间机械臂视/力多源信息融合自主操作技术。针对操作技能学习困难、学习效率低的问题，研究高效的深度强化学习技能学习算法，开展模拟空间环境下的在轨高精度插拔学习技术试验，并完成地面平台的实物测试。针对仿真环境和真实环境存在差异，仿真环境中学习到的技能难以在真实机械臂上应用的问题，研究深度强化学习算法的虚实迁移和多任务泛化技术。

### （二）研究内容

针对空间机械臂在轨精确手眼协同操作的研究，首先在物理仿真引擎搭建包括空间机械臂本体在内的工作场景，在此基础上对空间机械臂的运动学模型和动力学模型进行参数辨识，并对手眼相机和力传感器的位姿进行标定，建立支持视觉、力觉反馈的高拟真仿真环境，用于空间机械臂手眼协同操作的训练。其次，基于搭建的仿真环境，针对存在多源感知信息时空间机械臂手眼协同精确操作训练难度大的问题，开展对残差深度强化学习的研究，将基准控制算法的输出和深度强化学习算法的输出相结合作为空间机械臂的控制输入。残差深度强化学习可以将先验知识包含在基准控制算法中，以此简化深度强化学习的探索难度，实现高效的操作技能学习。最后，针对仿真环境中训练得到的模型向真实场景中迁移的问题，开展域随机化技术的研究，在训练过程中通过在仿真场景中的任务参数、模型参数在一定范围内随机选取使训练得到的模型具备对任务参数、模型参数的泛化能力。

**1. 支持视/力反馈的高精度插拔操作任务高拟真仿真场景建模**

空间机械臂在轨高精度操作仿真训练场景是进行深度强化学习训练的基

础，仿真场景的真实度决定了仿真环境中训练的模型向真实场景迁移的难度，据此开展高拟真仿真场景建模研究。首先，为了保证相同控制信号下的近似控制结果，仿真场景中的空间机械臂应与真实空间机械臂有相同动力学和运动学参数，这就需要获取真实空间机械臂在太空环境下的运动学和动力学模型参数。其次为了便于仿真环境中训练的模型向真实场景迁移，仿真场景中深度神经网络的输入应与真实环境中的深度神经网络的输入相近，考虑到空间机械臂在轨操作过程中的感知输入主要为相机图像和力与力矩信息，因此需开展空间机械臂手眼相机内外参数和力传感器位姿参数的标定技术研究。综上所述，需研究以下内容：

（1）空间机械臂在轨高精度插拔任务仿真场景三维建模；

（2）空间机械臂高精度运动学与动力学模型参数辨识；

（3）空间机械臂手眼相机内外参数与力传感器位姿参数标定。

**2. 基于残差深度强化学习的空间机械臂视/力融合操作高效学习**

由于空间机械臂在轨高精度操作任务涉及高维的视觉和力觉感知，同时空间机械臂的控制量为高维连续的，这使得空间机械臂高精度操作成为高维输入、高维连续输出的复杂学习问题，对深度强化学习算法的学习能力提出了很高的要求，因此需要开展空间机械臂视/力融合的高效学习算法研究。由于典型的在轨操作任务，如插拔操作，可以人为设计控制策略，通过将人为设计的控制策略与深度强化学习算法输出的控制量相结合可以简化深度强化学习的训练难度，使得学习过程更加高效、训练结果更好，二者融合的算法称为残差深度强化学习算法。综上所述，空间机械臂视/力融合的残差深度强化学习算法研究涉及以下内容：

（1）空间机械臂高维连续动作空间情况下的深度强化学习算法研究；

（2）空间机械臂插拔任务的人为启发式控制策略设计；

（3）融合启发式控制策略与深度强化学习算法的残差深度强化学习算法研究。

**3. 基于元强化学习与域随机化的操作技能迁移技术**

在仿真环境中训练得到的模型向真实场景应用时由于这两个场景之间存在难以避免的差异，导致训练得到的模型性能受到影响，因此需开展仿真场景向真实场景迁移时的迁移技术研究。域随机化技术通过在仿真训练过程中对影响控制效果的传感器参数进行随机选取来学习能够适应不同参数的操作技能，进而避免由于仿真环境与真实环境之间传感器参数差异导致的性能下将。制约强化学习算法应用的另一问题是相似任务之间的泛化问题，强化学习算法对任务非常敏感，以插拔操作为例，孔的形状和大小的改变都会使训练的模型失效，需要花费大量时间重新训练。因此需研究相似任务之间的泛化技术，元强化学习首先在任务集上对相似任务进行大量训练，学习到最佳的神经网络初始化参数，利用学习到的初始化参数在新的相似任务上训练时可以在很短时间内收敛。综上所述，基于元强化学习与域随机化的操作技能迁移技术涉及以下研究内容：

（1）典型高精度插拔任务的域随机化策略设计；

（2）典型高精度插拔任务的元强化学习任务集设计；

（3）空间机械臂高精度操作的元强化学习算法研究。

**（三）创新点**

**1. 一种支持视/力反馈的空间机械臂高精度插拔操作仿真环境**

针对深度强化学习算法对训练数据的大量需求而真实空间机械臂难以直接用于大量训练的问题，通过结合开源物理仿真引擎 MuJoCo 搭建高拟真的空间机械臂深度强化学习仿真训练环境，实现对复杂高精度插拔的接触动力学仿真。首先建立空间在轨插拔任务的三维场景模型，通过对空间机械臂的运动学和动力学参数进行辨识建立精确的空间机械臂仿真对象。针对空间机械臂在轨高精度操作对视/力融合感知的需求，在此仿真场景的基础上，建立高拟真的手眼相机和力传感器模型，为空间机械臂高精度在轨插拔操作技能学习提供有效支撑。

**2. 一种基于残差深度强化学习的空间机械臂视/力融合操作高效学习算法**

针对空间机械臂视/力融合高精度操作，在高维输入、高维连续输出的情况下难以有效训练的问题，通过将人为设计的启发式控制策略与深度强化学习控制策略相结合以简化深度强化学习的训练难度、提升训练效果。首先根据空间机械臂插拔操作的任务的特点制定启发式控制策略，以降低深度强化学习算法的探索难度，在此基础上利用支持高维连续动作输出的 SAC 深度强化学习算法进行复杂的实时力反馈控制，解决传统控制方法难以实现的多接触复杂操作问题。

**3．一种结合元强化学习和域随机化的操作技能迁移技术**

针对空间机械臂的仿真训练场景与真实场景存在差异导致仿真环境中训练的模型难以迁移到实际场景中进行训练的问题，通过域随机化技术对相机图像背景、相机位姿标定误差、目标位姿测量误差等参数进行随机初始化，使训练得到的模型能够适应上述参数在仿真和真实场景之间的差异。针对深度强化学习算法对任务参数非常敏感，当操作任务发生较小改变就需要花费大量时间重新训练的问题，利用元强化学习算法首先在一组任务集上对相似任务进行大量训练，学习到最佳的神经网络初始化参数，然后利用该初始化参数在新的相似任务上训练，此时只需少量交互数据即可快速收敛，从而解决深度强化学习算法训练得到的技能在相似任务上的泛化问题。

**（四）技术指标**

1. 支持不少于 3 种空间机械臂高精度插拔任务；
2. 仿真场景任务成功率>90%，地面演示系统任务完成成功率>80%；
3. 不同任务场景下的模型收敛次数<8×105 次；
4. 空间机器人单步动作规划时间<1ms;
5. 在相似任务下少量训练后的完成成功率>75%。

## 四、研究方案和技术途径

研究方案由三部分组成，分别为：支持视/力反馈的空间机械臂插拔操作高拟真仿真场景建模、基于残差深度强化学习的空间机械臂视/力融合操作高效学习、基于元强化学习与域随机化的操作技能迁移技术。三部分的关系如图 4 所示。

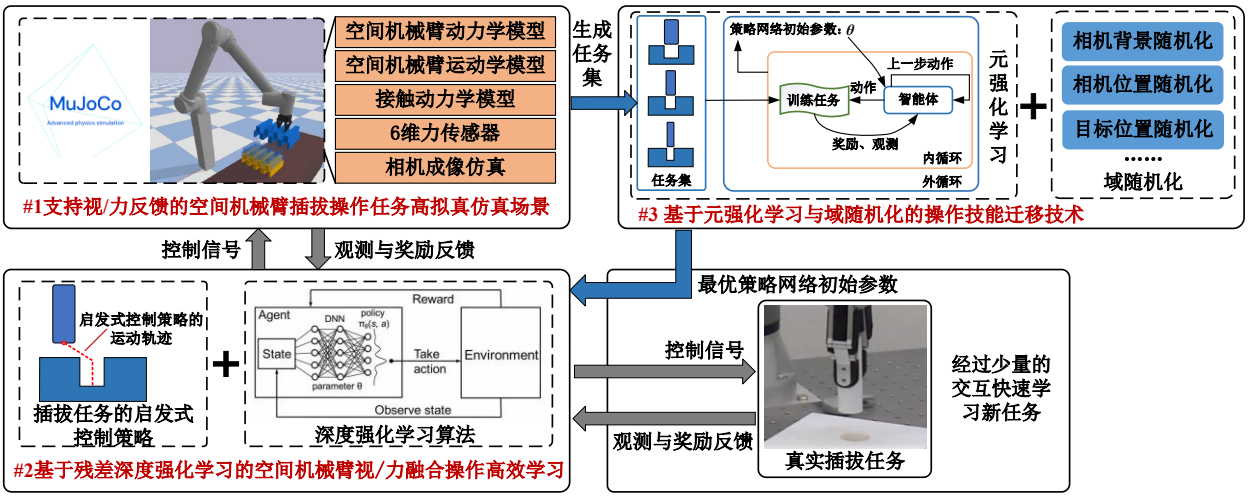



图 4 研究方案思路图

首先基于 MuJoCo 物理仿真引擎搭建空间机械臂高精度插拔任务的仿真训练场景，基于此仿真场景一方面可以为残差深度强化学习算法提供仿真训练服务，另一方面可以在仿真场景中调整任务参数（如改变插拔任务中插头和孔的尺寸）生成多组任务集用于元强化学习的训练，此外在训练过程中还可以利用域随机化技术随机改变仿真场景中的传感器参数。最终，元强化学习算法学习到的最佳策略初始参数用于初始化操作策略，通过在真实场景中进行少量交互即可实现空间机械臂的插拔操作。

### （一）支持视/力反馈的空间机械臂插拔操作任务高拟真仿真场景建模

仿真环境是进行无模型深度强化学习训练的基础，随着无模型深度强化学习在机器人领域得到广泛研究，随之出现了一批用于机器人训练的开源物理仿真引擎，具有代表性的是 MuJoCo、pybullte、Webots 等。物理仿真引擎为机器人动力学和运动学仿真提供了方便的接口，只需输入机器人的运动学参数、动力学参数和外观三维 CAD 模型文件，即可建立机器人的仿真对象。此外，

物理仿真引擎提供了基础的接触动力学模型和相机的成像仿真技术，可以实现 RGB 相机和深度相机的图像生成以及力信息反馈。空间机械臂精确操作仿真环境的结构组成如图 5 所示。

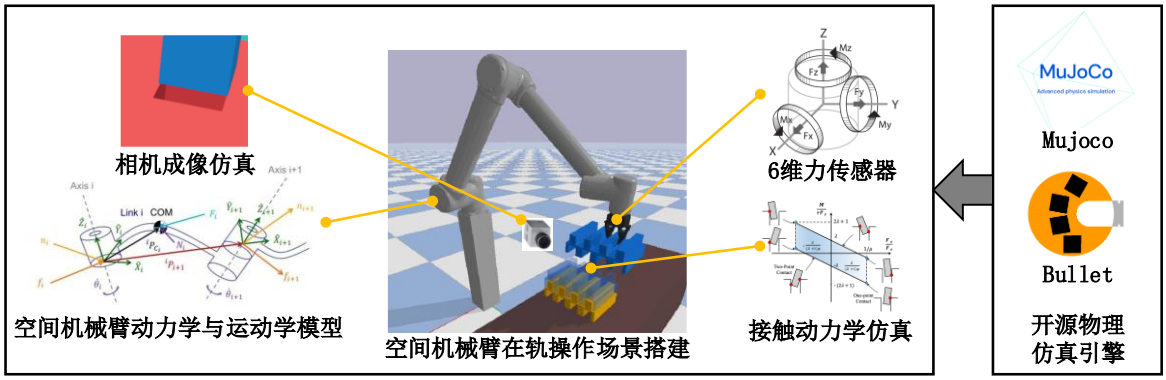



图 5 空间机械臂视/力融合操作仿真场景示意图

经过调研，MuJoCo 物理仿真引擎具备最好的接触动力学仿真性能，同时在机器人强化学习研究中应用广泛，因此拟采用 MuJoCo 物理仿真引擎用于空间机械臂在轨高精度操作任务的仿真训练。首先需要对典型的空间机械臂插拔操作场景进行 3 维 CAD 建模，并确定空间机械臂在工作空间中的位置。然后将建模得到的 3 维 CAD 模型文件导入 MuJoCo 仿真引擎中。接下来需要获取真实空间机械臂的运动模型参数和动力学模型参数。

空间机械臂的运动学模型通常利用 D-H 法建立，在 D-H 法中首先根据机械臂各关节的轴线方向和空间位置信息为每个连杆固连一个坐标系，通常情况下坐标系的 $z$ 轴与关节轴线方向重合、坐标系的原点选在相邻两个关节轴线与其公垂线的交点处，$x$ 轴的方向与公垂线方向重合，$y$ 轴基于 $z$ 轴和 $x$ 轴的方向用右手法则确定。坐标系 $\{i\}$ 与坐标系 $\{i-1\}$ 之间的相对位姿关系可以由 4 个 D-H 参数：$\alpha_{i-1}$、$a_{i-1}$、$d_i$、$\theta_i$ 来确定。$\alpha_{i-1}$ 指轴 $z_{i-1}$ 到轴 $z_i$ 需沿 $x_{i-1}$ 轴平移的距离；$a_{i-1}$ 指轴 $z_{i-1}$ 到轴 $z_i$ 需绕 $x_{i-1}$ 轴旋转的角度；$d_i$ 指轴 $x_{i-1}$ 到轴 $x_i$ 需沿 $z_i$ 轴平移的距离；$\theta_i$ 指轴 $x_{i-1}$ 到轴 $x_i$ 需绕 $z_i$ 轴旋转的角度。四个 D-H 参数对应了四个子变换，两个坐标系之间的位姿可以由四个子变换相乘得到。在仅有旋转关节的机械臂中$\alpha_{i-1}$、$a_{i-1}$、$d_i$ 三个参数为确定的值，只有 $\theta_i$ 为变量。为了便于位姿解

算，将坐标系$\{i\}$相对于坐标系$\{i-1\}$的姿态旋转矩阵和空间位置关系组合为一个$4\times4$的矩阵${}_{i}^{i-1}\boldsymbol{T}$，该矩阵称为齐次变换矩阵：

$$
\begin{aligned}
{}_{i}^{i-1}\boldsymbol{T} &= \mathrm{rot}\left(x_{i-1},\alpha_{i-1}\right)\mathrm{trans}\left(x_{i-1},a_{i-1}\right)\mathrm{trans}\left(z_i,\theta_i\right)\mathrm{rot}\left(z_i,d_i\right) \\
&= \begin{bmatrix} c_i & -s_i & 0 & a_{i-1} \\ s_i\cos\alpha_{i-1} & c_i\cos\alpha_{i-1} & -\sin\alpha_{i-1} & -\sin\alpha_{i-1}d_i \\ s_i\sin\alpha_{i-1} & c_i\sin\alpha_{i-1} & \cos\alpha_{i-1} & \cos\alpha_{i-1}d_i \\ 0 & 0 & 0 & 1 \end{bmatrix}
\end{aligned} \tag{1}
$$

上式中，规定$\sin\theta_i=s_i$，$\cos\theta_i=c_i$。依次将相邻坐标系之间的齐次变换矩阵相乘，即可计算机械臂的正运动学模型：

$$
{}_{7}^{0}\boldsymbol{T} = {}_{1}^{0}\boldsymbol{T}\,{}_{2}^{1}\boldsymbol{T}\,{}_{3}^{2}\boldsymbol{T}\,{}_{4}^{3}\boldsymbol{T}\,{}_{5}^{4}\boldsymbol{T}\,{}_{6}^{5}\boldsymbol{T}\,{}_{7}^{6}\boldsymbol{T} = \begin{bmatrix} n_x(\boldsymbol{q}) & o_x(\boldsymbol{q}) & a_x(\boldsymbol{q}) & p_x(\boldsymbol{q}) \\ n_y(\boldsymbol{q}) & o_y(\boldsymbol{q}) & a_y(\boldsymbol{q}) & p_y(\boldsymbol{q}) \\ n_z(\boldsymbol{q}) & o_z(\boldsymbol{q}) & a_z(\boldsymbol{q}) & p_z(\boldsymbol{q}) \\ 0 & 0 & 0 & 1 \end{bmatrix} \tag{2}
$$

上式中，$\boldsymbol{q}=\left.\theta_i\right|_{i=0}^{n}$表示机械臂所有关节角度组成的向量。综上所述，给定空间机械臂各连杆的 4 个 D-H 参数：$\alpha_{i-1}$、$a_{i-1}$、$d_i$、$\theta_i$ 即可确定空间机械臂在仿真环境中的运动学模型。空间机械臂精确的运动学模型可以利用高精度的位姿测量装置对机械臂进行标定得到。

空间机械臂的动力学模型通常由拉格朗日方程或牛顿-欧拉方程建立。漂浮基空间机械臂的多刚体动力学模型可以表示为如下形式：

$$
\begin{bmatrix} \boldsymbol{H}_b & \boldsymbol{H}_{bm} \\ \boldsymbol{H}_{bm}^T & \boldsymbol{H}_m \end{bmatrix}\begin{bmatrix} \ddot{\boldsymbol{x}}_b \\ \ddot{\boldsymbol{q}} \end{bmatrix} + \begin{bmatrix} \boldsymbol{c}_b \\ \boldsymbol{c}_m \end{bmatrix} = \begin{bmatrix} \boldsymbol{F}_b \\ \boldsymbol{\tau}_m \end{bmatrix} + \begin{bmatrix} \boldsymbol{J}_b^T \\ \boldsymbol{J}_m^T \end{bmatrix}\boldsymbol{F}_e \tag{3}
$$

其中，$\boldsymbol{\varphi}=\begin{bmatrix}\boldsymbol{x}_b & \boldsymbol{q}\end{bmatrix}^T$为系统的广义坐标，$\boldsymbol{H}(\boldsymbol{\varphi})$为惯量矩阵，$\boldsymbol{H}_b$、$\boldsymbol{H}_m$分别为空间基体、机械臂的惯量矩阵，$\boldsymbol{H}_{bm}$为基体和机械臂的耦合惯量阵，$\boldsymbol{c}_b$和$\boldsymbol{c}_m$是关于惯量矩阵的函数，$\boldsymbol{F}_b$为基体进行姿轨控时所受驱动力/力矩，$\boldsymbol{\tau}_m$为机械臂关节驱动力矩，$\boldsymbol{F}_e$为任务操作过程中末端所受力/力矩。综上所述，需给定空间机械臂的惯量矩阵才可在仿真环境中仿真空间机械臂的动力学模型。空间机械臂的动力学参数则需要进行参数辨识来获得。

建立空间机械臂本体的模型之后，需要在 MuJoCo 环境中添加传感器，在

高精度操作任务中，常用的传感器为 RGB 相机和 6 维力传感器。6 维力传感器的位姿可以通过机械臂的 CAD 模型文件测量得到。仿真环境中 RGB 相机的内、外参数需要与真实机械臂上的相机完全匹配，因此在搭建仿真训练环境之前需要在真实机械臂上对相机的内外参数进行标定获取精确的数值。典型的机器人相机配置包括手眼相机和全局相机，在高精度操作任务中机械臂末端的手眼相机能够更方便的观察装配位置，因而更适合用于本项目中。

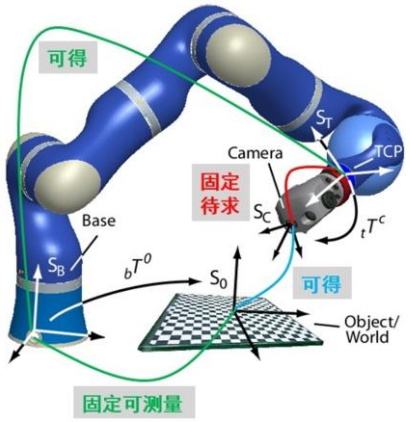



图 6 手眼相机标定坐标系示意图

当相机固定于机械臂末端时，此时相机坐标系与机械臂末端坐标系的变换关系固定，而与基座坐标系的变换关系会时刻变化，待求量为相机坐标系到机械臂末端坐标系的变换矩阵 ${}^{end}\boldsymbol{T}_{camera}$。根据各个坐标系的关系，可以列出来如下的坐标变换方程：

$$ {}^{base}\boldsymbol{p} = {}^{base}\boldsymbol{p}_{end}\,{}^{end}\boldsymbol{p} = {}^{base}\boldsymbol{T}_{end}\,{}^{end}\boldsymbol{T}_{camera}\,{}^{camera}\boldsymbol{p} \tag{4} $$

上式中，${}^{base}\boldsymbol{p}$ 代表固定在某个位置的棋盘格的点到机器人基座坐标系的坐标，此坐标可以直接测量得到，${}^{camera}\boldsymbol{p}$ 可以用相机识别棋盘格角点 3D 坐标的方法得到。相机坐标系到机器人末端坐标系的转换矩阵 ${}^{end}\boldsymbol{T}_{camera}$ 则通过下式计算：

$$ \left({}^{base}\boldsymbol{T}_{end}\right)^{-1}\,{}^{base}\boldsymbol{p}\left({}^{camera}\boldsymbol{p}\right)^{-1} = {}^{end}\boldsymbol{T}_{camera} \tag{5} $$

综上所述，支持视/力反馈的空间机械臂操作任务高拟真仿真场景建模需要结合 MuJoCo 物理仿真引擎执行下列步骤：建立工作环境的 3 维 CAD 模型、识别空间机械臂的运动学和动力学参数、标定相机的内外参数、确定 6 维力传感器的位姿。

## （二）基于残差深度强化学习的空间机械臂视/力融合操作高效学习

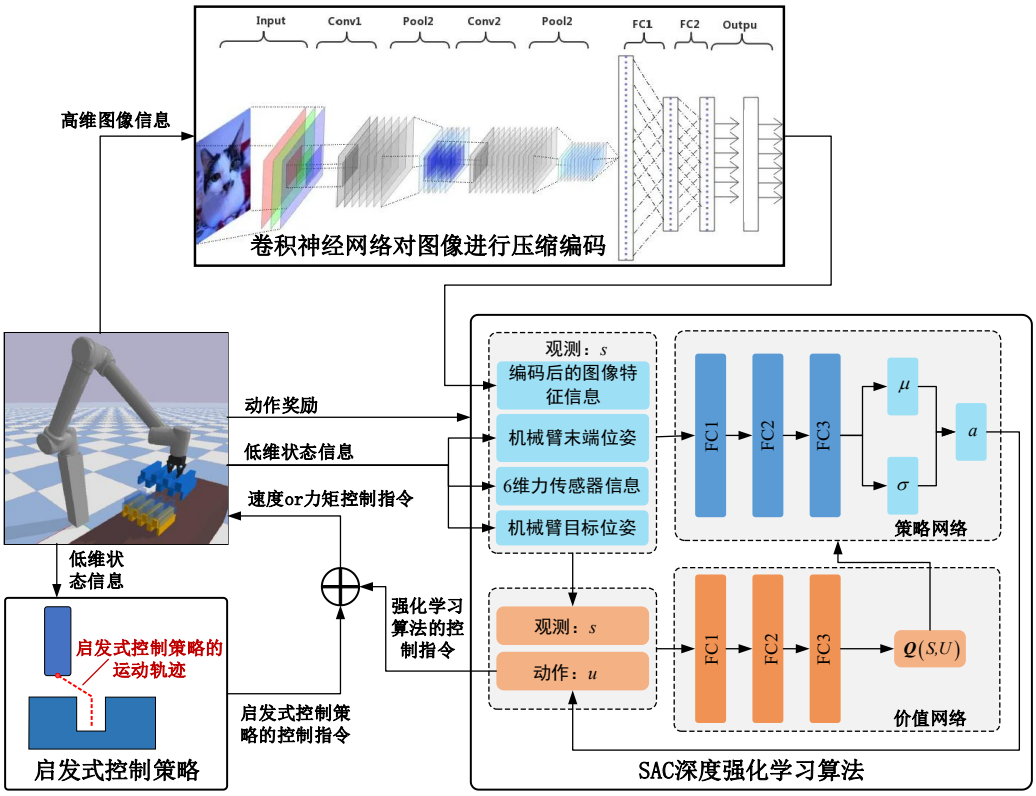



图 7 基于残差深度强化学习的空间机械臂视/力融合操作技能学习示意图

空间机械臂的插拔操作过程可以分为不涉及复杂接触的基础运动过程和需要进行复杂力控的装配过程，不涉及复杂接触的基础运动过程可以通过设计启发式控制策略来实现。以插拔操作为例，当知道孔的位置时可以直接控制机械臂末端向孔靠近，然后向下运动插入，这个控制策略可以手工设计。但是机械臂末端与孔接触并向下插入的过程需要根据实时的力反馈来实现精确的柔顺装配，当涉及复杂的力反馈控制时传统的控制方法难以实现，而深度强化学习算法是近年来兴起的有效控制方法。

残差深度强化学习是将启发式控制策略的控制量与深度强化学习的控制输出相结合的控制方法。将启发式控制策略表示为$\pi_H(s)$，深度强化学习控制策略表示为$\pi_\Phi(s)$，则残差深度强化学习的总控制输出为：

$$u=\pi_H(s)+\pi_\Phi(s) \tag{6}$$

接下来对残差深度强化学习的实施过程进行介绍。首先选取训练机械臂操作技能的深度强化学习算法。因为空间机械臂的动作空间为高维连续的动作空

间，而 SAC（soft-actor-critic）算法在高维连续动作空间的任务中有很强的稳定性和更好的训练效果，因此选取 SAC 算法来学习机械臂的操作技能。SAC 算法是一种动作-评论家（actor-critic）架构的深度强化学习算法，需要训练一个策略网络来生成动作，训练一组价值网络对动作进行评价。策略网络的输出即可作为空间机械臂的控制指令，动作可以有多种形式，如机械臂的关节速度、关节力矩或机械臂末端执行器的运动速度等，需要根据具体的任务进行确定。价值网络是对当前状态下策略网络决策好坏的估计，表示在当前状态 $s$ 下采取动作 $a$ 的情况下策略的累计期望奖励。

为了实现更加稳定和高效的连续动作空间中的训练，SAC 算法将策略的熵加入策略网络的学习目标中，在最大化期望累计回报的同时使策略尽可能的随机。将策略熵表示为 $\mathcal{H}(\pi)$，其计算公式为：

$$\mathcal{H}(\pi)=-\mathbb{E}_{\pi}\left[\log(\pi)\right] \tag{7}$$

增加了策略熵之后策略网络的优化目标变为：

$$\pi^{*}=\arg\max_{\pi}\mathop{\mathrm{E}}_{\tau\sim\pi}\left[\sum_{t=0}^{\infty}\gamma^{t}\left(R(s_t,a_t)+\alpha\mathcal{H}\left(\pi(\cdot|s_t)\right)\right)\right] \tag{8}$$

在 SAC 算法中，动作价值函数表示为 $Q_{\theta}(s,a)$，其对应的神经网络参数表示为 $\theta$；策略函数表示为 $\pi_{\phi}(a|s)$，其对应的神经网络参数为 $\phi$。首先对动作价值网络进行更新，动作价值网络的损失函数根据贝尔曼公式进行计算：

$$\begin{cases} J_Q(\theta)=\mathbb{E}_{(s_t,a_t,r_t,s_{t+1})\sim\mathcal{D}}\left[\dfrac{1}{2}\left(Q_{\theta}(s_t,a_t)-y\right)^2\right] \\ y=r_t+\gamma\mathbb{E}_{a_{t+1}\sim\pi}\left[Q_{\bar{\theta}}(s_{t+1},a_{t+1})+\alpha\mathcal{H}\left(\pi_{\phi}\right)\right] \end{cases} \tag{9}$$

上式中，$\bar{\theta}$ 是目标动作价值网络的参数，在每次计算 $J_Q(\theta)$ 的梯度时，$\bar{\theta}$ 按照下面的方式进行软更新。

$$\bar{\theta}=\tau\theta+\ 1-\tau\ \bar{\theta} \tag{10}$$

为了缓解动作价值函数对价值的高估，SAC 算法采用同样的方式训练了两个动作价值网络，分别用 $Q_{\theta_1}$ 和 $Q_{\theta_2}$ 来表示，在计算 $Q_{\bar{\theta}}(s_{t+1},a_{t+1})$ 的值时选取较小

的那个动作价值函数的值，即：

$$Q_{\bar{\theta}}\left(s_{t+1},a_{t+1}\right)=\min\left(Q_{\bar{\theta}_1}\left(s_{t+1},a_{t+1}\right),Q_{\bar{\theta}_2}\left(s_{t+1},a_{t+1}\right)\right) \tag{11}$$

两个动作价值网络的损失函数$J_Q(\theta_i)$，$i=1,2$的梯度计算公式为：

$$\nabla_{\theta_i}J_Q(\theta_i)=\nabla_{\theta_i}Q_{\theta_i}\left(a_t,s_t\right)\left(Q_{\theta_i}\left(s_t,a_t\right)-r_t-\gamma Q_{\bar{\theta}}\left(s_{t+1},a_{t+1}\right)+\gamma\alpha\log\left(\pi\right)\right) \tag{12}$$

在 SAC 算法中策略网络的输出为动作的均值$\mu_\phi(s)$ 和标准差$\sigma_\phi(s)$，真实的动作则根据均值和标准差采样得到，即$a\sim\mathcal{N}(\mu_\phi(s),\sigma_\phi^2(s))$，由于采样这个过程无法计算梯度，因此在 SAC 中利用了重参数化方法，将从$\pi_\phi(\cdot|s)$中采样转换为计算一个由状态$s$、策略参数$\phi$和独立噪声$\xi$为变量的确定性函数。

$$\tilde{a}_\phi(s,\xi)=\tanh\left(\mu_\phi(s)+\sigma_\phi(s)\cdot\xi\right),\xi\sim\mathcal{N}(0,I) \tag{13}$$

上式中$\tanh(\cdot)$表示 tanh 激活函数，经过重参数化之后策略网络可以方便地对$\phi$计算梯度。策略网络的损失函数为：

$$J_\pi(\phi)=\mathbb{E}_{s_t\sim\mathcal{D},\xi_t\sim\mathcal{N}}\left[\log\pi_\phi\left(\tilde{a}_\phi\left(s_t,\xi_t\right)|s_t\right)-Q_\theta\left(s_t,\tilde{a}_\phi\left(s_t,\xi_t\right)\right)\right] \tag{14}$$

表 1 残差深度强化学习算法伪代码

**残差深度强化学习算法**

1. **Initialize** 初始化强化学习策略$\pi_\phi$和手工设计的启发式控制策略$\pi_H$
2. **for** each episode **do**
3. 随机生成起始状态$s_0$
4. **for** each step **do**
5. 计算强化学习的控制输出$u_\phi\sim\pi_\phi(\cdot|s_t)$
6. 计算启发式控制输出$u_H$
7. 计算总控制量$u_t=u_\phi+u_H$
8. 计算下一步的状态$s_{t+1}\sim p(\cdot|s_t,u_t)$
9. 计算奖励$r_t$
10. 存储交互数据$\left(s_t,u_\phi,s_t,r_t\right)$到回放缓冲区中
11. 从回放缓冲区从采样数据并利用 SAC 算法更新策略参数
12. **end for**
13. **end for**

在空间机械臂手眼协同精确操作任务中，深度强化学习控制策略的状态输入包含四部分内容，分别是手眼相机的图像信息、机械臂手腕处的 6 为力传感

器信息、机械臂的末端位姿信息以及装配目标位姿信息。其中相机的图像信息需要利用深度卷积网络进行特征提取，将压缩之后的低维特征信息作为深度强化学习策略网络的输入。深度强化学习涉及的策略网络和价值网络都为 3 层的全连接神经网络。

与深度强化学习控制策略相比，启发式控制策略较为简单，需要根据具体的任务进行设计。以机械臂插孔任务为例，启发式控制策略可以设计为两段运动轨迹，即靠近阶段的轨迹和插入阶段的轨迹，在操作过程中控制机械臂的末端沿着规划好的轨迹运动即可。综上所述，残差深度强化学习的实现过程伪代码如表 1 所示。

### （三）基于元强化学习与域随机化的操作技能迁移技术

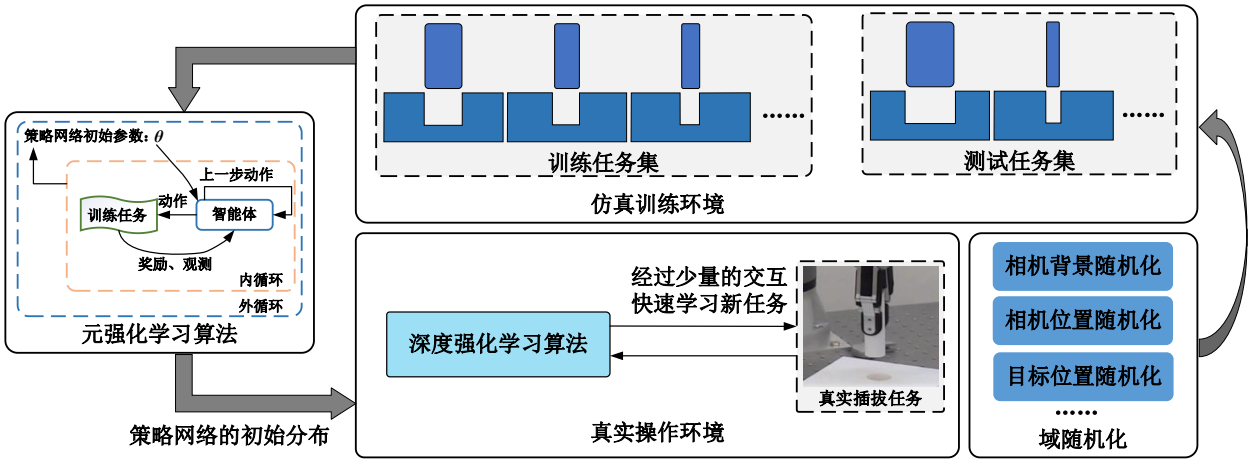



图 8 基于元强化学习与域随机化的操作技能迁移示意图

标准的深度强化学习的目标是针对特定的马尔科夫决策过程（Markov decision process，MDP），通过某些深度强化学习算法（如 DQN、DDPG、SAC 等）求解一个最优策略，指导智能体在特定任务下做出最佳决策。深度强化学习中的学习算法依赖于智能体与环境之间的大量交互，训练成本高，且一旦环境发生变化，原本学习好的最优策略就不再适用，此时必须针对新的环境重新训练，这显然是十分低效的。

针对这一问题，可以在标准深度强化学习中引入元学习。元学习的目标是通过学习得到比重新训练更为高效的学习算法，这些学习算法能够从过去的任

务中获取历史经验，从而迅速适应新任务。当所学习的任务为 MDP，所学习的学习算法为 DRL 算法时，这一过程就变成了元强化学习。可以看出，普通 DRL 学习的是特定任务下的最优策略，而元强化学习的则是能够迅速适应不同新任务并得到相应最优策略的学习算法，即学习如何学习（learn to learn），把学习一个 RL 算法本身当作了一个 RL 问题。

MAML（Model-Agnostic Meta-Learning）是当前用得最多的元学习算法之一，MAML 的思想是训练得到一套模型的初始参数，使得该模型仅通过少量样本上的一次或几次梯度更新就能够最大化新任务的性能。从特征学习的观点来看，这一过程可以看作是构建一个适用于许多任务的内部表征，此时只需要简单地微调参数（例如仅修改最上层的神经网络系数）就能够在某一特定任务上获得很好的结果。MAML 的思想可以用于解决空间机械臂高精度操作在相似任务上的泛化问题。首先生成一组相似的操作任务集，以高精度插拔操作为例，可以通过在一定范围内随机改变孔和棒的大小来实现，接下来在任务集上将 MAML 引入强化学习算法来初始化策略网络的参数，这样当遇到新的孔棒大小时即可利用少量数据进行快速学习，达到对相似任务的泛化目标。下面对 MAML 进行详细介绍。

考虑一个模型 $f$ 用于将观测 $s$ 映射为输出 $a$，元学习中的模型需要适应大量不同的任务，这里的每个任务 $\mathcal{T}=\left\{\mathcal{L}\left(s_1,a_1,\ldots,\mathrm{s}_H,a_H\right),q\left(s_1\right),q\left(s_{t+1}|\ s_t,a_t\right),H\right\}$ 包含一个损失函数 $\mathcal{L}(\cdot)$，一个初始观测的分布 $q\left(s_1\right)$，一个转移分布 $q\left(s_{t+1}|\ s_t,a_t\right)$，以及单个训练回合的长度 $H$。在元强化学习中，假设模型需要适应的不同任务均服从同一分布 $\rho(T)$。考虑一个 $K$ 样本学习场景，在元训练过程中，首先从 $\rho(T)$ 中采样得到一个任务 $\mathcal{T}_i$，然后用 $K$ 个样本以及这些样本的损失函数 $\mathcal{L}_{\mathcal{T}_i}$ 对模型进行训练，并将训练之后的模型用 $\mathcal{T}_i$ 产生的新样本进行测试。最终，采样任务 $\mathcal{T}_i$ 上的测试误差将作为元学习过程的训练损失函数。上述过程实际上也包含一个内部循环与一个外部循环。在内部循环中，采样新的任务，对模型训练，用

更新后的参数对模型测试；在外部循环中，将各采样任务在测试集上的误差作为损失函数对模型进行训练，这里的模型是内部循环中更新前的模型，每个内部循环中对模型的更新只会用于产生该任务的测试误差，最终元学习所更新的模型是初始模型。在强化学习任务中，模型 $f$ 即为智能体的策略网络，每个任务的损失函数表示为：

$$\mathcal{L}_{T_i}\left(\pi_\phi\right)=-\mathbb{E}_{s_t,a_t\sim\pi_\phi,qT_i}\left[\sum_{t=1}^{H}R_i\left(s_t,a_t\right)\right] \tag{15}$$

MAML 元深度强化学习的伪代码如下表所示：

表 2　MAML 元深度强化学习算法伪代码

**MAML 元深度强化学习算法**

1. **Initialize** 初始化任务分布 $\rho(T)$，学习步长 $\alpha$，$\beta$，网络初始参数 $\phi$
2. **for** each episode **do**
3. 采样一组任务 $T_i\sim\rho(T)$
4. **for** each $T_i$ **do**
5. 利用 $\pi_\phi$ 在任务 $T_i$ 上采样 $K$ 条轨迹 $\mathcal{D}=\{(s_1,a_1,\ldots s_H)\}$
6. 利用 $\mathcal{D}$ 和 $\mathcal{L}_{T_i}$ 计算 $\nabla_\phi\mathcal{L}_{T_i}\left(\pi_\phi\right)$
7. 计算策略网络参数 $\phi_i^{'}=\phi-\alpha\nabla_\phi\mathcal{L}_{T_i}\left(\pi_\phi\right)$
8. 利用 $\pi_{\phi_i^{'}}$ 在任务 $T_i$ 上采样 $K$ 条轨迹 $\mathcal{D}_i^{'}=\{(s_1,a_1,\ldots s_H)\}$
9. **end for**
10. 利用每个 $\mathcal{D}_i^{'}$ 更新初始参数 $\phi\leftarrow\phi-\beta\nabla_\phi\sum_{T_i\sim\rho(T)}\mathcal{L}_{T_i}\left(\pi_\phi^{'}\right)$
11. **end for**

元强化学习是实现近似任务之间快速迁移的技术途径，域随机化技术是实现仿真环境到真实环境迁移的有效方法，尤其是当策略网络的输入存在高维图片信息时，仿真环境中的图片信息很难保证与真实场景下完全一致，相机的外参也可能存在无法，此时域随机化技术通过对仿真环境中相机的光亮、背景、颜色等进行随机生成，同时使相机的位置在一定范围内随机波动，以此使训练得到的策略网络能够适应相机渲染差异和外参标定误差导致的迁移问题。

## 五、研究进度与成果形式

### （一）研究进度

表 3 进度安排

| 年度 | 年度目标 | 年度研究内容 | 年度成果形式 |
|---|---|---|---|
| 2022 年 | 完成空间机械臂在轨高精度插拔任务的仿真训练场景搭建，并实现残差深度强化学习算法的训练与测试。 | （1）完成空间机械臂深度强化学习仿真训练环境的搭建；<br>（2）完成基于残差深度强化学习空间机械臂高精度插拔操作仿真训练。 | （1）《空间机械臂在轨高精度插拔操作仿真训练研究报告》<br>（2）空间机械臂在轨高精度插拔操作仿真训练软件。 |
| 2023 年 | 完成空间机械臂在插拔操作任务集上的元强化学习训练，并实现学习到的操作技能在真实空间机械臂平台上的成功率测试。 | （1）完成基于元强化学习与域随机化的空间机械臂插拔操作任务仿真训练；<br>（2）完成仿真训练的模型在真实机械臂上的操作测试；<br>（3）完成仿真训练的模型在相近任务上的泛化能力测试。 | （1）《空间机械臂在轨高精度插拔操作多任务迁移测试研究报告》<br>（2）《空间机械臂在轨高精度插拔操作实物测试研究报告》<br>（3）空间机械臂在轨高精度插拔操作技能模型<br>（4）空间机械臂在轨高精度插拔操作应用软件 |

### （二）成果形式

1. 报告类成果

（1）《空间机械臂在轨高精度插拔操作仿真训练研究报告》

（2）《空间机械臂在轨高精度插拔操作多任务迁移测试报告》

（3）《空间机械臂在轨高精度插拔操作实物测试研究报告》

2. 模型类成果

（1）空间机械臂在轨高精度插拔操作技能模型。该模型主要包括训练得到的插拔操作技能的深度神经网络模型。

3. 软件类成果

（1）空间机械臂在轨高精度插拔操作应用软件。该软件主要包括基于开源物理仿真引擎开发的仿真训练环境以及基于深度强化学习技能模型的空间机械臂控制程序。

六、研究条件与保障措施

1、现有研究条件

2、保障措施

3、协作单位

| 协作项目 | 主要协作要求 | 协作单位 | 协作经费 |
|---|---|---|---|
| | | | |
| | | | |

七、承担研究任务主要人员概况

1、项目负责人简介

2、主要研究人员概况

| 姓　名 | 年　龄 | 学　历 | 单　位 | 年工作时间 | 备　注 |
|---|---|---|---|---|---|

| | | | | | |
|---|---|---|---|---|---|
| | | | | | |
| | | | | | |
| | | | | | |
| | | | | | |
| | | | | | |
| | | | | | |
| | | | | | |
| | | | | | |
| | | | | | |

八、经费概算

1、经费概算

2、主要开支内容

九、审查意见

| | |
|---|---|
| 应用单位意见 | 签字<br>盖章<br>年　　月　　日 |
| 学校审查意见 | 签字<br>盖章<br>年　　月　　日 |
| 一院审查意见 | 签字<br>盖章<br>年　　月　　日 |