空间双臂机器人在轨高精度插拔操作
仿真训练研究报告

单位名称

哈尔滨工业大学航天学院

二○二六年七月

空间双臂机器人在轨高精度插拔操作仿真训练研究报告

拟制：

校对：

标审：

审核：

批准：

单位名称

哈尔滨工业大学航天学院

二○二六年七月

目 录

1 高精度插拔操作任务高拟真仿真场景建模 2
1.1 空间双臂机器人在轨高精度插拔任务仿真场景三维建模 2
1.2 空间双臂机器人高精度运动学与动力学模型参数辨识 2
1.3 空间双臂机器人手眼相机内外参数标定 2
2 空间双臂机器人高精度插拔操作高效学习 3
2.1 用于空间双臂机器人高精度插拔操作的深度强化学习算法 4
2.1.1 强化学习理论基础 4
2.1.2 DQN 算法 7
2.1.3 SAC 连续动作深度强化学习算法 9
2.2 空间双臂机器人插拔任务的人为启发式控制策略设计 11
2.2.1 先验控制器的运动学与动力学基础 11
2.2.2 导纳型柔顺控制理论 14
2.3 融合启发式控制策略与深度强化学习算法的残差深度强化学习算法 18
2.3.1 启发式控制策略与深度强化学习算法的融合方法 18
2.3.2 训练参数 23
2.3.3 训练结果 27
2.3.4 装配测试 30

1 高精度插拔操作任务高拟真仿真场景建模

XXXX

1.1 空间双臂机器人在轨高精度插拔任务仿真场景三维建模

图 1 XXXX

XXXX

1.2 空间双臂机器人高精度运动学与动力学模型参数辨识

图 2 XXXX

1.3 空间双臂机器人手眼相机内外参数标定

XXXX

2 空间双臂机器人高精度插拔操作高效学习

空间双臂机器人高精度插拔操作同时涉及末端相对位姿调整、视觉与力觉信息感知、接触约束处理以及动作序列决策。直接采用深度强化学习生成底层控制量，需要在高维状态与动作空间中进行大量探索；仅依赖固定规则又难以适应初始偏差、配合尺寸、传感误差和控制参数的变化。针对上述问题，本章采用“启发式控制提供可执行基线、深度强化学习学习环境相关修正、底层控制器实现运动与柔顺响应”的研究思路，建立面向空间双臂机器人高精度插拔操作的高效学习方法。

按照项目研究任务，本章的方法目标是形成支持视 / 力融合感知和高维连续动作输出的残差深度强化学习方案。首先介绍强化学习、DQN 和 SAC 的基本原理；随后结合运动学、动力学与导纳型柔顺控制设计启发式策略；在此基础上构建启发式控制量与学习控制量融合的残差策略，并给出状态、动作、奖励、随机化和测试方法。当前软件已完成结构化状态输入、离散动作 DQN 及部分域随机化训练，可作为方法链路的阶段性验证；视觉编码、连续动作 SAC 和显式残差叠加仍属于后续实现内容。

本章理论组织遵循“决策理论—机器人模型—柔顺执行—残差学习—训练测试”的逻辑。强化学习部分说明策略优化依据；运动学与动力学部分建立动作执行的模型基础；导纳控制部分规定接触响应；残差强化学习部分明确启发式控制与学习修正的融合关系。通

用理论采用统一符号表述，不将单臂模型参数或其他实验统计直接作为空间双臂系统的参数与结果。

2.1 用于空间双臂机器人高精度插拔操作的深度强化学习算法

2.1.1 强化学习理论基础

强化学习研究智能体如何通过与环境交互获得决策规律。其基本要素包括状态、动作、奖励、策略和环境转移。智能体在时刻 t 获得状态 s_t，依据策略选择动作 a_t，环境返回奖励 r_{t+1}并转移至下一状态 s_{t+1}。与监督学习利用给定正确标签不同，强化学习通常只能获得动作后果的评价，需要解决延迟奖励、探索与利用以及长期信用分配问题。[1]

标准离散时间问题可用马尔可夫决策过程描述，其要素记为 M＝(S，A，P，R，γ)。S 和 A 分别为状态空间与动作空间；P 描述给定状态和动作后的转移概率；R 描述即时奖励；γ 为折扣因子。马尔可夫假设要求下一时刻状态的条件分布由当前状态和动作决定，而不再依赖更早的历史。如果观测不能完整反映环境，则需将问题视为部分可观测决策问题，或通过历史信息构建近似充分的状态。

$$G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \cdots$$

其中，G_t为从时刻 t 开始的折扣回报。对无限时域且奖励有界的问题，通常取 $0\le\gamma<1$ 以保证回报有界；有限回合也可在满足条件时取 γ＝1。γ 越接近 1，算法越强调后续收益，但价值估计也会受

到更长时间范围内误差的影响。优化目标是寻找使期望回报最大的策略，而不是逐步选择即时奖励最大的动作。

$$V^{\pi}(s) = E_{\pi}[G_t \mid s_t = s]，\ Q^{\pi}(s,a) = E_{\pi}[G_t \mid s_t = s，\ a_t = a]$$

状态价值函数 V 描述遵循策略 π 从状态 s 出发的长期收益；动作价值函数 Q 进一步规定第一步执行动作 a，公式中上标 π 表示所遵循的策略。两者通过后续策略联系起来。利用回报的递推关系，可将长期价值分解为一步奖励与下一状态价值，从而不必等到整条轨迹结束后才更新估计。

为完整说明价值函数的递推过程，先考虑离散状态和动作下的固定策略评价。令 π(a|s)为状态 s 下选择动作 a 的概率，P(s′|s,a)为状态转移概率，R(s,a,s′)为该转移的期望即时奖励。由 $G_t = r_{t+1} + \gamma G_{t+1}$，并对动作选择和下一状态分别取条件期望，可得到贝尔曼期望方程。[4]

$$V^{\pi}(s) = \sum_a \pi(a|s) \sum_{s'} P(s'|s,a)[R(s,a,s') + \gamma V^{\pi}(s')]$$

$$Q^{\pi}(s,a) = \sum_{s'} P(s'|s,a)[R(s,a,s') + \gamma V^{\pi}(s')]$$

$$V^{\pi}(s) = \sum_a \pi(a|s) Q^{\pi}(s,a)$$

第一式回答“给定策略有多好”，第二式回答“先执行某个动作，再遵循该策略有多好”；第三式把动作价值按策略概率加权还原为状态价值。连续状态下应将对状态的求和替换为相应积分。奖励可能同时依赖下一状态，上述写法不要求将奖励简化成仅由当前状态决定的常数。

进一步将固定策略下的评价转为最优决策，在有限动作集合中选择使长期收益最大的动作。最优状态价值等于各动作最优价值的最大值，因此将下一状态的策略平均替换为最大化操作，即得到下述最优动作价值关系。该转换说明了为什么 Q-learning 与 DQN 的目标包含下一状态动作价值的最大值，而不是只比较当前一步奖励。

$$Q^*(s,a) = E[r_{t+1} + \gamma \, max_{a'} Q^*(s_{t+1},a') \mid s,a]$$

当转移模型未知时，无法直接枚举上述期望，但可以使用交互样本估计更新目标。以固定策略的状态价值评价为例，TD(0)采用一步奖励和下一状态的当前估计构造目标：

$$\delta_t = r_{t+1} + \gamma V(s_{t+1}) - V(s_t)$$
$$V(s_t) \leftarrow V(s_t) + \alpha\delta_t$$

这里的 TD 误差统一定义为“目标减当前估计”。TD 利用尚未完全准确的价值估计更新另一估计，称为自举；与等待整回合结束再使用完整回报的蒙特卡洛方法相比，它可以在每一步交互后更新。状态价值评价本身并不直接给出动作选择，Q-learning 进一步学习动作价值，并用贪心目标进行策略改进。

前述 Q*公式为最优动作价值的贝尔曼关系。时序差分学习将采样得到的一步目标与当前估计进行比较，利用差值修正价值函数；Q 学习以“下一状态最优动作价值”为更新目标，因此可以使用由探索策略产生的数据学习贪心目标策略，是典型的离策略方法。

$$\delta_t = r_{t+1} + \gamma \, max_{a'} Q(s_{t+1},a') - Q(s_t,a_t)$$
$$Q(s_t,a_t) \leftarrow Q(s_t,a_t) + \alpha\delta_t$$

学习率 α 决定单次估计修正的幅度。探索用于发现尚未充分尝试的动作，利用则选择当前估计价值最高的动作；两者需要随数据积累逐步平衡。终止状态与时间截断也应分开理解：任务真正终止后不再存在未来回报，单纯因采样时长被截断则不一定意味着其后价值为零。

2.1.2 DQN 算法

当状态变量连续或组合数量较大时，逐项存储 Q 表不再实用。深度 Q 网络以参数化函数 Q(s,a；θ)近似动作价值，一次前向计算得到有限动作集合中各动作的价值估计。网络结构应与输入形式匹配：图像输入可以使用卷积结构，本项目使用的是结构化数值观测，对应全连接网络，而不是直接由图像端到端输出动作。[2]

为降低连续采样数据的相关性，DQN 将状态转移保存到经验回放集合，再随机抽取小批量样本训练。另设目标网络 Q(s,a；θ^-)计算更新目标，并间隔若干次学习复制在线网络参数，降低目标值随每次梯度更新快速变化带来的不稳定性。终止样本的自举项通过终止标志 d 屏蔽。

$$y_i = r_i + \gamma(1-d_i)\, max_{a'}\, Q(s_i', a';\ \theta^-)$$

$$L(\theta) = \frac{1}{B}\sum_i [y_i - Q(s_i, a_i;\ \theta)]^2$$

其中，B 为批量大小，θ 和 θ^-分别为在线网络和目标网络参数。标准 DQN 将目标 y 视为常数，仅对在线预测分支求梯度。训练循环由交互采样、回放存储、批量更新和目标网络同步组成；评估阶

段冻结网络参数并使用事先确定的测试策略，不能继续边测试边更新再将结果称为独立评估。

从表格更新到神经网络更新，改变的是价值函数的表示方式。网络共享参数 θ，使不同状态的经验通过参数更新相互影响；相近状态是否得到合理泛化，仍取决于输入表征与训练样本，而不是使用神经网络后自动成立。在固定批次目标值的前提下，网络通过损失梯度更新参数：

$$\theta \leftarrow \theta - \eta \nabla_{\theta} L(\theta)$$

η 是优化器学习率，与折扣因子 γ 的作用不同。Adam 依据梯度的一阶与二阶矩估计调整各参数的更新尺度，并不自动调整 γ，也不负责决定探索概率。学习率决定“每次改多少”，γ 决定“未来收益看多远”，探索概率决定“采样时多大程度尝试非贪心动作”，三者必须分别配置。

经验回放与目标网络解决的问题也不同：经验回放对已采集转移随机抽样，降低小批量样本的时序相关性并复用数据；目标网络在若干次更新期间保持参数不变，减缓自举目标的快速漂移。两者有助于改善训练，但不构成非线性 DQN 必然收敛的证明。[4]

本项目采用两层各 128 个神经元的隐藏层和 ReLU 激活，当前输入为 22 维、输出为 10 维，优化器为 Adam。需注意代码中的 epsilon 表示“选择贪心动作的概率”，与部分教材将 ε 定义为随机探索概率

的记号相反。当前 epsilon 从 0 递增至 0.9，即随机动作概率从 1 降低至 0.1，而不是探索概率逐渐增加。

实现核对还发现，当前学习函数计算 q_next 时未显式停止梯度，且均方误差作用于整个动作向量；这与上式按所选动作定义、固定目标值的标准写法不完全一致。因此本节公式用于说明标准 DQN 机制，不能以公式代替对现有程序训练细节的检查。后续若规范该实现，应单独保存新版本与日志，避免将不同训练版本混为一组结果。

2.1.3 SAC 连续动作深度强化学习算法

按照项目研究目标，空间机械臂操作具有高维连续动作特征，并选用软演员—评论家算法（Soft Actor-Critic，SAC）学习操作策略。SAC 是一种离策略演员—评论家算法：策略网络 πφ(a|s)输出连续动作分布，两个动作价值网络 Qθ1 与 Qθ2 评价状态—动作对，目标网络提供相对平稳的自举目标。与只能从有限动作集合中选择动作的 DQN 相比，SAC 能够直接表示末端位置、姿态、速度或关节控制量等有界连续动作。[5]

SAC 采用最大熵强化学习目标，在最大化累计奖励的同时提高策略熵。策略熵反映动作分布的不确定性，温度系数 α 用于平衡任务奖励和随机探索，其目标可写为：

$$J(\pi) = E_{\pi}[\sum_t \gamma^t r(s_t, a_t) + \alpha H(\pi(\cdot|s_t))]$$

α 较大时策略更加重视动作多样性，α 较小时更接近只优化奖励的常规强化学习。α 可以固定，也可以通过目标熵自动调整；目标熵、动作缩放和奖励量级共同影响训练，因此不能脱离动作维度直接照搬其他任务的 α。

对于回放池中的转移(s，a，r，s′，d)，采用两个评论家网络抑制价值高估。令 a′由当前策略在 s′处采样，d 表示真实终止标志，软 Q 目标为：

$$y = r + \gamma(1-d)[min_{j=1,2}Q_{\theta j}(s',a') - \alpha log\pi_{\varphi}(a'|s')]$$

$$L_Q(\theta_j) = E_D[Q_{\theta j}(s,a) - y^2]$$

策略网络在提高评论家给出的动作价值的同时保留适当熵，其损失可写为下式；梯度通过重参数化动作 a=fφ(ε；s)计算，其中 ε 为与策略参数无关的随机噪声：

$$L_{\pi}(\varphi) = E_{s\sim D,\varepsilon}[\alpha log\pi_{\varphi}(a|s) - min_{j=1,2}Q_{\theta j}(s,a)]$$

$$\theta_j \leftarrow \tau\theta_j + (1-\tau)\theta_j$$

最后一式为目标评论家网络的软更新，τ 通常取远小于 1 的正数。SAC 仍使用经验回放，但策略、评论家和温度参数分别优化。训练时应分别记录评论家损失、策略损失、温度系数、策略熵和回合奖励，不能只凭奖励曲线判断所有网络均已稳定。

面向视 / 力融合的状态可写为 s＝[φI(I)，w，Δx，q，q̇，z]：φI(I)为手眼图像的低维特征，w 为六维力 / 力矩，Δx 为轴孔相对位姿，q 与 q̇ 为关节状态，z 为任务与域参数。图像编码器可使用卷积网络，但输入维数、归一化方式和训练数据必须随实现一并确定。若当前

阶段未接入图像，则不能将 22 维结构化状态称为已经实现视 / 力融合。

连续动作建议在末端参考层定义为 a＝[Δp，Δω]或相应速度指令，并按各方向独立限幅。平移量与转动量具有不同单位，需要分别归一化和缩放；动作经安全投影后再与启发式控制量融合。若改用关节速度或关节力矩，必须同步调整动作边界、底层接口和安全监督，不能只替换策略网络输出维度。

2.2 空间双臂机器人插拔任务的人为启发式控制策略设计

人为先验控制器承担可由模型与工程规则直接描述的部分，包括坐标变换、姿态保持、径向纠偏、接近速度限制及底层运动跟踪。强化学习不需要从零探索这些基本规律，而是在给定动作接口内学习调整方向与推进时机。先验控制器必须能够在不调用学习策略时独立运行，才能形成残差算法中可对照的基线。

2.2.1 先验控制器的运动学与动力学基础

机械臂控制模型可由连杆坐标变换、雅可比矩阵和拉格朗日动力学建立。[4] 这些内容在本报告中用于解释末端动作如何转化为可执行运动。这里保留一般串联机械臂的建模方法，不照搬 UR10 的六关节 D-H 参数表；当前双臂模型的连杆、关节轴、质量和惯量应由对应 URDF 及场景配置确定。

正运动学建立关节变量 q 与末端位姿之间的映射。采用改进 D-H 约定时，相邻坐标变换依次为绕前一连杆 x 轴旋转、沿该轴平移、绕当前 z 轴旋转和沿该轴平移。以 R 与 T 分别表示旋转和平移算子，四个参数为连杆扭角 α、连杆长度 a、关节角 θ 与关节偏距 d：

$$A_i = R_x(\alpha_{i-1})T_x(a_{i-1})R_z(\theta_i)T_z(d_i)$$

$$T_{0e}(q) = A_1A_2\cdots A_nT_{tool}$$

其中 T_{0e}表示末端坐标系在基坐标系下的位姿，Ttool 为末端工具安装变换，n 为该运动链的关节数。各变换均为 4×4 齐次矩阵，由 3×3 旋转矩阵 R、三维位置 p 和末行[0，0，0，1]组成。改进 D-H 与标准 D-H 的坐标系约定不同，不能把某一约定的参数表与另一约定的乘法顺序混合使用。

双臂装配关注的不仅是每个末端的绝对位姿，还包括轴端相对于孔端的位姿。若 T_WL 和 T_WR 分别表示左、右末端在同一世界坐标系 W 下的位姿，则右末端坐标系下的左末端位姿为 T_RL＝$(T_WR)^{-1}T_WL$。由此可统一定义相对位置和轴线夹角，并区分世界坐标系与工具坐标系中的动作方向。该相对变换是对本科单臂模型的双臂扩展说明，实际轴、孔参考帧需与 object_tip 和 target_tip 一致。

微分运动学通过雅可比矩阵 J(q)建立关节速度与末端速度的关系。令 v_e为由线速度和角速度组成的六维向量，则：

$$v_e = J(q)\dot{q}，\ \dot{v_e} = J(q)\ddot{q} + \dot{J}(q)\dot{q}$$

当单臂具有 7 个关节时，J 为 6×7 矩阵，通常不能直接求普通矩阵逆。理论上可用伪逆求取满足任务速度的关节速度，并利用零空间自由度处理关节限位等次级目标；接近奇异构型时还需考虑阻尼、限速或轨迹调整。这些是模型控制器需要处理的条件，不代表当前代码已实现全部措施。

动力学进一步描述实现上述运动所需的关节力矩。采用拉格朗日建模思路，令 L＝T−U 为系统动能与势能之差，将各连杆的平动和转动动能汇总后，可写成关节空间矩阵形式：

$$M(q)\ddot{q} + C(q,\dot{q})\dot{q} + g(q) + \tau_f = \tau + J^T(q)F_{ext}$$

M 为惯性矩阵，Cq̇ 表示科里奥利力与离心力的组合项，g 为重力项，τf 为摩擦力矩，τ 为执行器输入；本式 Fext 定义为环境作用于末端的六维力 / 力矩，因此右端取正号。若将力定义为机械臂作用于环境的反力，符号需相应改变。所有力、速度与雅可比必须采用一致坐标系，不能直接混用不同传感器坐标下的分量。

在固定基座、模型准确且外力已处理的理想条件下，逆动力学控制通过补偿 M、C 与 g 等项，使关节加速度跟随指定辅助输入。这解释了“任务空间参考—关节运动—驱动力矩”的执行链。但空间双臂系统若基座自由运动，需将基座状态与两臂关节共同纳入广义动力学模型，单臂固定基座方程只能作为局部基础；不能仅将重力项设为零就等同于完整在轨动力学。

2.2.2 导纳型柔顺控制理论

机械臂装配接触过程可区分为自由运动、碰撞过渡和平稳接触三个阶段。[4] 自由运动阶段主要控制末端位姿；接触发生时，环境约束使接触力快速变化；进入持续接触后，则需要同时考虑位置偏差与交互力。高定位精度并不意味着能在定位误差和刚性约束下完成柔顺装配，这正是引入力学反馈与柔顺模型的原因。

阻抗与导纳描述相同的力—运动动态关系，但实现时的输入和输出不同。力矩型阻抗控制通常根据运动偏差形成目标笛卡尔力，再通过雅可比转置等模型关系生成关节力矩；导纳型控制则把测得的外力偏差输入虚拟动力学模型，得到位置、速度或加速度修正，并交由运动跟踪内环执行。以力偏差为输入、以运动修正为输出的基于位置实现，在本章统一称为“导纳型柔顺控制”。

为描述接触条件下的运动响应，取末端相对参考轨迹的局部位姿误差为 e，采用质量—阻尼—刚度形式构造期望动态关系。对于小范围姿态偏差，可将位置误差与局部旋转误差组合为六维向量；平移与转动参数具有不同物理单位，不能只因矩阵维数相同就将两者解释为同一种刚度。

$$M_d\,\ddot{e} + D_d\,\dot{e} + K_d\,e = \Delta F$$

其中，M_d、D_d 和 K_d 依次为期望惯性、阻尼和刚度矩阵，ΔF 为按照既定坐标系与符号约定定义的外力偏差。该关系将力偏差

映射为允许的运动变化。对于参数恒定、正定且输入为零的理想线性误差系统，候选能量函数可写为动能项与弹性势能项之和。

$$E = \frac{1}{2}\dot{e}^T M_d \dot{e} + \frac{1}{2} e^T K_d e，\ \dot{E} = -\dot{e}^T D_d \dot{e} \leq 0$$

上述分析仅说明理想误差模型的耗散性质，不等于完整机器人系统在离散执行、接触切换、模型误差和饱和限制下已经获得稳定性证明。实际控制器还需要将末端目标加速度映射到关节空间，并处理基座运动、动力学耦合以及关节力矩的符号与索引。

代码中 Kp、Kd 和 Md 分别对应上述刚度、阻尼和虚拟质量角色。当前调用链的 forceI 被置为零，虽然采集了末端外力 he，但生效的加速度表达式采用 forceI，后续 getAqt2 调用也未传入 he。因此目前更准确的表述是“具有虚拟质量—阻尼—刚度参数的轨迹跟踪实现”，尚不能据此声称已实现完整外力偏差闭环导纳调节。报告保留导纳理论作为设计依据，并明确其与当前外力反馈通路的差异。

为进一步解释参数的作用，将上述六维关系在采用对角参数、忽略轴间耦合的局部假设下投影到某一方向，记虚拟质量、阻尼和刚度为 m、d、k。零初值下，对单方向质量—阻尼—刚度方程作拉普拉斯变换，可得到力偏差到位移修正的传递函数：

$$Y(s) = \frac{E(s)}{\Delta F(s)} = \frac{1}{ms^2 + ds + k}$$

$$\omega_n = \sqrt{\frac{k}{m}}，\ \zeta = \frac{d}{2\sqrt{mk}}，\ e_{ss} = \frac{\Delta f_0}{k}$$

这里 s 为拉普拉斯复变量，与强化学习状态符号不同；ωn 为无阻尼自然频率，ζ 为阻尼比，e_{ss}为恒定力偏差 Δf_0下的稳态位移。相同外力下，增大 k 会减小柔顺位移；固定 m、k 时，增大 d 提高阻尼比，有助于抑制振荡，但过度阻尼会减慢响应；固定 d、k 时，增大 m 降低自然频率且同时降低阻尼比。因而“惯性越大越稳定”或“阻尼越大越好”都不是普遍结论。[4]

上述 ζ<1、ζ＝1、ζ>1 分别对应理想二阶模型的欠阻尼、临界阻尼和过阻尼情形，仅用于局部参数分析。真实闭环还包含机器人跟踪内环、接触刚度、采样延迟和饱和限制，因此不能仅靠正定参数或一个阻尼比判定整个装配系统安全稳定。实际整定应先验证无接触跟踪，再测试受控接触，最后加入学习策略。

在完整导纳实现中，外环求得的是相对名义轨迹的柔顺修正 ξ，跟踪内环接收 xcmd＝xnom＋ξ；这与 DQN 为任务推进产生的参考增量处在不同层次。应分别保存名义轨迹、柔顺修正与学习修正，避免重复叠加。当前代码外力通路的实现边界已在上文说明，此处给出的是理论控制架构。

2.2.2.1 先验动作生成与分阶段控制

人为先验动作可围绕“先径向对准、后轴向推进”构建。设轴孔径向误差向量为 e⊥，其模长为 ρ，轴向剩余距离为 d_x。设计中首先依据径向误差生成受限纠偏量；只有误差低于阶段阈值时才允许较快轴向接近，临近入口后减小步长，避免在未充分对准时持续推进。

$$u_{H,\perp} = sat(-k_h e_\perp, u_{\perp,max})$$

其中 sat 表示幅值限制，k_h 为人工纠偏增益。该公式给出待实现的确定性基线：没有学习修正时，控制器仍可按误差方向行动。其增益、动作限幅及切换阈值需要通过独立基线测试确定，不能把 DQN 已经选出的动作反过来称为人为先验动作。

现有环境已实现自适应粗插入步长规则：剩余距离大于 100 mm 时采用 30 mm；处于 60～100 mm 时依据 10 mm 对准阈值选择 20 或 15 mm；处于 30～60 mm 时依据 6 mm 阈值选择 15 或 8 mm；进入 30 mm 内后，仅当对准误差小于 1.5 mm 才允许 5 mm 推进，否则该粗插入动作取零位移。该规则只在选择相应粗插入动作时生效，不能理解为所有动作均受到同样的前进门控。

现有底层将左臂参考位置和姿态交给模型控制器执行，右臂采用关节 PD 保持初始目标位置。右臂比例和阻尼系数分别为 1500 和 100。右臂“保持目标”不意味着其在接触作用下完全静止，应由关节误差和末端漂移记录验证保持效果。左臂动作在自身末端坐标系定义，再旋转到世界坐标系，因此动作符号不能脱离当前末端姿态直接解释为世界轴正负方向。

2.2.2.1.1 参数作用、约束与切换条件

刚度决定位置偏差产生的纠正作用，阻尼决定误差速度响应，虚拟质量影响瞬态加速度。较大刚度可能提高跟踪能力，也可能增大接触时的刚性响应；阻尼过小易出现振荡，过大可能导致动作迟

缓。应在相同初始条件下比较误差收敛、接触峰值和完成时间，而不是仅凭某一参数数值大小判断控制品质。

设计中的安全监督应高于启发式和学习动作优先级，至少包括关节限位、碰撞监测、力与力矩限幅、越界终止及接触异常回撤。现有程序保存了 force_limit＝80 的配置，但当前奖励终止分支没有使用该值触发力超限终止，不能将日志中的零次 force_limit 解释为全部回合都满足 80 N 安全约束。拔出阶段还需增加轴向反向动作、允许接触力范围和完全脱离判据；当前 10 种网络动作不包含独立的反向拔出动作。

2.3 融合启发式控制策略与深度强化学习算法的残差深度强化学习算法

残差强化学习的核心是保留一个具有基本功能的控制策略，再由学习器补偿其不足。[3] 本章选取末端参考位移层作为融合层，避免将网络直接输出解释为未经约束的关节力矩。需要特别区分“网络输出位移增量”与“在确定性控制动作上叠加残差”：前者只是增量式动作表达，后者还要求明确存在先验项、残差项及其融合关系。

2.3.1 启发式控制策略与深度强化学习算法的融合方法

2.3.1.1 状态表示与离散动作

现有基础状态由轴孔相对位置的 3 个分量、左臂末端力与力矩的 6 个分量，以及左臂 7 个关节位置组成，共 16 维。相对轴向距离

使用绝对值，径向分量保留符号。打开域参数输入后，追加位置刚度比例、姿态刚度比例、阻尼比例、质量比例、轴径和间隙 6 个分量，网络输入扩展为 22 维。

域参数采用线性范围映射进行归一化，而基础 16 维状态没有统一归一化。间隙的实际计算范围为 0.5～3.0 mm，但当前用于归一化的 hole_clearance_range 为 0.5～2.0 mm，较大间隙会映射到 1 以上。后续可统一量纲或修正范围，但需作为新的训练设置单独记录。由于状态未包含全部速度、接触模式和环境变量，其马尔可夫充分性仍是近似假设，而非代码已经证明的性质。

表 2-1　现有 DQN 离散动作及环境映射

环境动作	含义	参考位移
1	精细插入	末端局部−Z 方向，5 mm
2、3	精细径向调整	末端局部 X 方向，±1 mm
4、5	精细径向调整	末端局部 Y 方向，±1 mm
6、7	粗略径向调整	末端局部 X 方向，±10 mm
8、9	粗略径向调整	末端局部 Y 方向，±10 mm
10	自适应粗插入	末端局部−Z 方向，0～30 mm

现有 10 种动作包括 1 种精细插入、4 种精细径向调整、4 种粗略径向调整和 1 种自适应粗插入。神经网络动作索引为 0～9，训练入口加 1 后传入环境。环境虽然存在 action＝0 时不施加位移的分支，但该分支不属于当前网络的 10 个输出，不能称为已经学习了零残差动作。

插拔操作可采用“DQN 决策子系统＋基于位置的阻抗控制子系统”的两层结构：前者决定下一步怎样调整，后者负责实现动作对应的运动响应。[4] 本报告在此基础上进一步区分三个层次：任务层选择对准或推进动作，参考层组合先验与学习修正，执行层跟踪参考并处理柔顺响应。这样能够说明各模块的职责，避免把 DQN、导纳控制和残差控制当作同一种算法。

两种“补偿”也应明确区分：导纳补偿依据即时力偏差满足给定动力学关系；学习补偿依据累计奖励改善动作序列，解决仅靠局部规则难以处理的初始偏差和推进时机问题。若网络直接选择全部参考增量，则属于学习决策驱动的分层控制；只有保留独立先验项，并在同一物理量、同一坐标系和同一更新周期下叠加网络项，才构成本章讨论的显式残差融合。

2.3.1.2 显式残差融合设计与现有实现边界

设 $u_H(s_t)$为先验控制器给出的位移增量，$u_R(s_t,a_t)$为 DQN 选定的有限残差动作，β 为残差幅值系数，则设计中的下一参考位置可写为下式。Π_U 表示投影或限幅，保证融合位移处于预先规定的动作集合约束内。

$$p_{ref,t+1} = p_t + \Pi_U[u_H(s_t) + \beta u_R(s_t, a_t)]$$

β＝0 时退化为启发式基线；逐步增大 β 可扩展学习修正的作用范围。训练初期宜优先保证基线可执行，再逐渐开放残差权限；但限幅不自动构成安全证明，仍需独立监督接触力、碰撞和关节约束。

为允许“不修正基线”，残差动作集中应显式包含零动作，网络输出维度需要与新动作集合一致。

当前 envStep 实际采用“当前位置＋所选动作位移”生成左臂参考位置，随后执行 50 个底层控制步；没有显式计算上式中的 u_H 与 βu_R 之和。因此已有日志可以用于分析启发式规则辅助下的 DQN 训练，不能用于证明完整残差 DQN 优于普通 DQN。本章残差融合公式、零动作和 β 调度为设计方案，尚待单独实现和验证。

2.3.1.3 奖励函数与训练流程

奖励应同时评价径向误差下降与轴向接近，并抑制未对准时推进。定义 ρ_t为径向误差，$d_{x,t}$为轴向剩余距离，$\Delta\rho=\rho_{t-1}-\rho_t$，$\Delta d=d_{x,t-1}-d_{x,t}$；程序以 $h=\max(0.030-d_{x,t},0)$构造计算插入深度，所有长度按米代入。当前普通步奖励为：

$$r_{base} = 2500\Delta\rho + r_a + 200\,max(0,0.003-\rho) + 20\,min(h,0.020) - 8\rho - 0.02$$

当 $\rho<0.003$ 时，$r_a=900\Delta d$；未满足该条件而 $\Delta d>0$ 时，$r_a=-250\Delta d$；其余情况 $r_a=50\Delta d$。该设计使对准后的接近获得较高奖励，并对尚未对准时继续前进施加惩罚。h 为几何代理量，其与真实接触嵌入深度的一致性必须结合场景几何核查。

插入深度超过 20 mm 时奖励为−60 并终止；径向误差超过 60 mm 或较初态后退超过 50 mm 时奖励为−40 并终止；达到 200 步时采用 r_base−10 终止；满足径向阈值且 h≥8 mm 时采用 r_base＋100

并终止。程序先检查超时再检查成功，因此第 200 步即使达到几何条件也会记为超时。独立测试应预先统一终止条件的优先级。

当前训练流程按回合重置、抽样域参数、物理预定位、获取状态、选择动作、执行控制、保存转移并更新网络。学习判断使用每回合内 step>100 且 step 为 5 的倍数，而不是全局累计交互步数；较早结束的回合可能没有触发学习。经验包含 done，并在目标值中屏蔽结束回合的自举项。若后续将时间截断与任务终止分开，需要同步调整回放字段和目标值定义。

2.3.1.4 面向视 / 力融合连续动作的残差 SAC 方案

项目目标方案将启发式控制策略 uH(s)作为基线，将 SAC 策略输出 uRL(s)作为连续残差，并在同一末端参考层进行融合。为避免学习策略破坏基本操作逻辑，残差输出先按平移、转动方向分别缩放，再经过动作边界、安全约束和阶段门控：

$$u_{cmd} = \Pi_{safe}(u_H(s) + \beta(s) \odot S_a u_{RL}(s))$$

Sa 为不同动作分量的尺度矩阵，β(s)为随操作阶段变化的残差权限，⊙表示逐元素乘法，Πsafe 表示限位、限速、接触力约束和碰撞约束构成的安全投影。靠近阶段可由启发式策略主导；进入接触与精细调整阶段后逐步增加学习修正权限。该表达式属于目标实现，不代表仅用 DQN 选择一个位移动作就已完成显式残差 SAC。

训练状态应同时保存名义轨迹、启发式输出、原始残差、缩放后残差、最终控制指令和安全投影触发原因，以便判断性能提升来

自学习修正还是安全层截断。消融测试至少包含启发式基线、无启发式 SAC、残差 SAC 三组，并在相同随机任务集和随机种子上比较成功率、完成时间、最终误差、峰值接触力和安全终止次数。

SAC 训练参数包括策略 / 评论家学习率、折扣因子 γ、回放池容量、批量大小、软更新系数 τ、温度系数 α 或目标熵、每次环境交互后的梯度更新次数、随机探索步数、动作尺度与残差系数 β。项目研究任务尚未规定这些参数的最终数值，当前 DQN 配置也不能直接替代 SAC 配置；因此应在 SAC 实现后按“固定场景调通—接触安全验证—单因素随机化—联合随机化”的顺序确定，并冻结版本与日志。

2.3.2 训练参数

本节以当前训练入口的实参为准，不将被注释的旧参数或环境构造函数的默认值混入同一配置。表中“范围”表示抽样或判定的配置范围，不表示实际机器人已达到的运动能力。长度统一转换为 mm 便于阅读；进入计算和日志的长度单位仍为 m。

表 2-2　网络与训练更新参数（现有入口）

参数	取值	含义及口径
状态/动作维度	22 / 10	16 维观测＋6 维域参数；10 种动作
隐藏层/激活	128、128 / ReLU	两层全连接隐藏层
learning_rate	0.0005	Adam 学习率
reward_decay	0.95	折扣因子 γ
memory_size	10000	回放容量，按转移条目计
batch_size	64	每次学习抽取样本数

参数	取值	含义及口径
replace_target_iter	300	按学习更新次数同步目标网络
epsilon 初值/上限	0 / 0.9	代码中为贪心动作概率
e_greedy_increment	0.0004	每次学习后递增贪心概率
训练回合	500（计划）	实际完成量以日志条数为准
learn 触发条件	step>100 且 step%5=0	step 每回合重新计数
损失/优化器	MSE / Adam	实现差异见 2.1.2
随机种子	NumPy 42；Torch 2	当前代码；不等于仿真全部确定性
模型保存	训练循环结束后	中途日志不保证有对应权重
日志保存	每回合结束后	奖励、成功、随机化与失败原因

表 2-3　动作、控制与终止参数（现有入口）

参数	配置值	作用
dt	0.005 s	控制器积分时间步；需核对仿真步长
action_steps	50	每个决策动作执行的内循环步数
linear_step	1 mm	精细径向位移
coarse_linear_scale	10	粗径向步长为 10 mm
insertion_step	5 mm	精细插入参考位移
coarse_insertion_step	30 mm	粗插入步长上限
adaptive_coarse_insertion	True	开启分段粗插入步长
coarse_insert_alignment_gate	1.5 mm	近入口粗插入允许条件
pre_insert_distance	30 mm	计算插入深度的参考距离
max_steps	200	每回合决策步数上限
max_align_error	60 mm	径向越界终止阈值
最大深度/后退量	20 / 50 mm	过深与轴向后退终止边界
最小成功深度	8 mm	当前几何代理深度判据
force_limit	80（配置）	当前终止分支未据此执行限力
reset_preposition_steps	500	物理偏差预定位过程步数
action_frame	left_ee	动作在左末端坐标系表达
control_mode	admittance	配置标签；实际通路见 2.2.2
Kp 基准对角项	180×3；80×3	分别为位置和姿态刚度

参数	配置值	作用
Kd/Md 基准	4Kp / 1.2Kp	分别为阻尼和虚拟质量配置
右臂关节 PD	1500 / 100	比例与速度阻尼系数
verbose/debug_interval	True / 20	输出开关与打印间隔

表 2-4　域随机化参数与精度判据（现有入口）

参数	取值或范围	含义
random_xy_min/max	10 / 25 mm	径向偏差半径的均匀抽样边界
偏差方位角	0～2π	方位均匀抽样；非面积均匀分布
randomize_physical_reset	True	通过物理预定位施加偏移
randomize_controller_gains	True	启用增益与虚拟质量随机化
kp_linear_scale_range	0.75～1.25	位置刚度缩放倍率
kp_angular_scale_range	0.85～1.15	姿态刚度缩放倍率
kd_scale_range	0.80～1.20	阻尼倍率
md_scale_range	0.80～1.20	虚拟质量倍率
randomize_geometry	True	启用轴对象几何缩放
peg_diameter_choices	16、17、18、19、20、21 mm	当前离散抽样集合
peg_diameter_range	16～21 mm	连续回退抽样/归一化范围
nominal_peg_diameter	18 mm	轴几何缩放基准
fixed_hole_diameter	22 mm	固定孔径参数；未缩放孔对象
实际单边间隙 c	0.5～3.0 mm	(22 mm−轴径)/2
hole_clearance_range	0.5～2.0 mm	当前归一化范围，非实际抽样范围
peg_length_axis	x	径向缩放模式的轴向定义
scale_peg_length	True	当前整体缩放，长度也改变
include_domain_params_in_state	True	追加 6 维域参数
success_alignment_limit	clip(0.75c,0.35,1.20) mm	派生精度阈值，不是独立抽样
模型与参考帧	见正文	场景对象/URDF/帧需一致

当前轴径为离散抽样，孔径在程序中固定为 22 mm；单边间隙由二者之差的一半得到，没有独立随机改变孔径。scale_peg_length 为真时调用整体缩放，轴长也随轴径改变；任务表中的轴径不能被理解为唯一发生变化的几何属性。应以 physical_peg_scaled 和实际场景检查确认对象缩放成功，并保存几何版本。

位姿模型配置使用 mulit_arm_urdf2.urdf，末端参考帧为 object_tip 和 target_tip，基准位姿设为[0,0,0.5,0,0,0,1]。这些模型与帧约定必须保持一致，否则相同动作可能对应不同的物理位移。verbose 和 debug_interval 控制输出信息，不改变理论目标；模型保存路径、日志路径及随机种子则用于保证实验可追溯性。

上述域随机化还可从导纳参数的角度解释。对某一平移或转动方向，设基准值为 m_0、d_0、k_0，抽样倍率分别为 λm、λd、λk，则自然频率与阻尼比相对基准值满足：

$$\frac{\omega_n}{\omega_{n0}} = \sqrt{\frac{\lambda_k}{\lambda_m}},\ \frac{\zeta}{\zeta_0} = \frac{\lambda_d}{\sqrt{\lambda_m \lambda_k}}$$

因此独立改变刚度、阻尼和虚拟质量会同时改变响应速度与阻尼特性，不能将各倍率当作互不影响的参数。位置刚度倍率和姿态刚度倍率应分别用于对应方向的 λk。训练范围扩大前，可按上式筛查极端组合，并通过真实闭环试验确认可执行范围；该筛查只提供整定依据，不替代接触与安全验证。

随机化整定可按分阶段试验组织。首先固定几何、偏差与增益，验证动作方向和几何判据；随后仅改变初始偏差，确认策略能在目标误差范围内对准；再分别引入几何和增益变化，最后进行联合随机化。每次扩大范围均应保留前一阶段冻结策略的独立评估结果，避免把环境难度上升导致的性能下降误判为网络结构无效。

对参数敏感性进行研究时，应一次只改变一类因素，并固定其余因素与测试种子；训练中的联合随机化则用于提高覆盖面。当前精度阈值由间隙派生，并不是独立的第四类随机变量。如需验证“尺寸、初始偏差、控制参数、精度要求”四类独立初始化，必须增加独立精度要求的输入或评估配置，不能仅修改报告文字。

2.3.3 训练结果

本节分析当前 DQN 阶段性实现保存的日志快照，不重新运行训练。选取 A 组 800 回合自适应插入记录和 B 组 192 回合多参数随机化记录，分别检查奖励、成功标志、随机化参数与失败原因的一致性。该结果用于验证离散动作训练链路，不用于评价尚未实现的视 / 力融合连续动作残差 SAC。

表 2-5　已保存训练日志统计（非独立测试）

记录组	回合数	成功数	训练成功比例	均值奖励	失败构成
A：自适应插入	800	260	32.5%	79.30	超时 477；过深 51；越界 12
B：多参数随机化	192	0	0%	−87.27	超时 169；越界 23

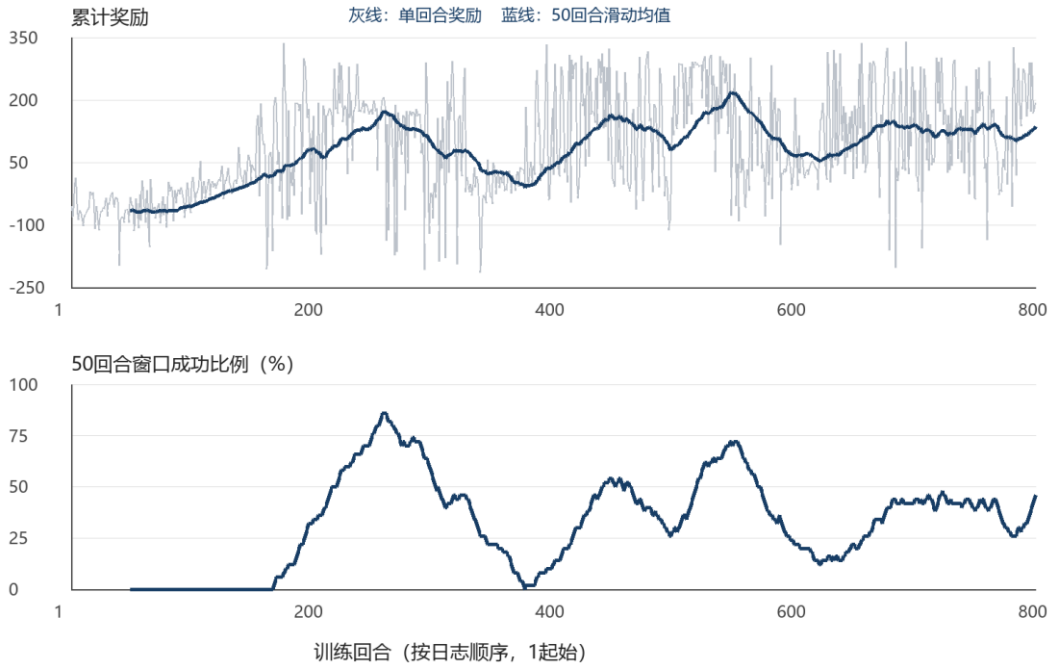


图 2-1　A 组 800 回合自适应插入训练曲线

图 2-1 给出了 A 组逐回合累计奖励及 50 回合滑动均值，同时绘制相同窗口内的训练成功比例。累计奖励前 50 回合均值为 −65.57，末 50 回合为 135.88，说明该次训练在后期能够获得更多有利的阶段奖励；前 100 回合没有成功，末 100 回合成功 42 次，表明学习过程出现了任务完成能力，但距离稳定高成功率仍有明显差距。

A 组全程 800 回合成功 260 次，总体比例 32.5%；其余包括超时 477 次、插入过深 51 次和越界 12 次。超时约占 59.6%，是主要未完成类型。奖励变化提示策略取得了阶段性进展，但尚不能据此将所有超时归因于某一个控制参数；需要结合动作序列、距离变化及接触信息进一步定位原因。末 100 回合 42%的训练成功比例也不是冻结策略的独立测试成功率。

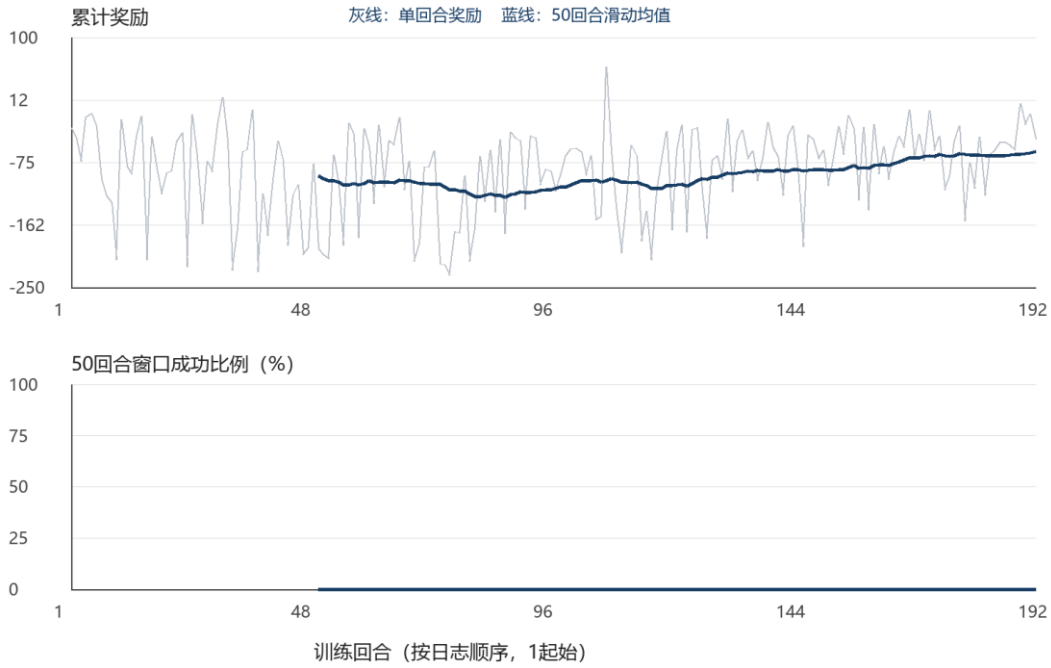


图 2-2　B 组 192 回合多参数随机化训练曲线

B 组采用轴径与控制参数随机化，当前 192 回合均未达到成功条件，其中超时 169 次、越界 23 次。前 50 回合奖励均值为−94.11，末 50 回合为−60.33；奖励有所改善，但成功次数仍为零。这说明阶段奖励变好与完整装配成功并不等价，当前数据不支持“已收敛”或“达到 90%成功率”的结论。

两组日志并非只改变单一因素的严格消融实验，A 组记录也未包含 B 组全部域参数字段。因此图 2-1 与图 2-2 应分别解读，不能仅以两条曲线的高低证明某种随机化或残差算法更优。B 组还应结合整体几何缩放、状态归一化范围、有效学习次数以及末端动作跟踪进行排查，相关因素目前属于待验证解释。

奖励曲线的纵轴为每回合各步奖励之和，既受动作质量影响，也受回合长度和奖励系数影响。图中的 50 回合均值从第 50 回合开

始计算，不填造前 49 回合的窗口值；窗口成功比例只用于描述训练趋势。当前日志未保存可用于本报告的连续损失历史、完整接触峰值和可靠仿真操作时间，不补画这些指标，也不以决策步数直接替代实测完成时间。

2.3.4 装配测试

2.3.4.1 100 组独立任务的随机初始化方案

为验证泛化能力，设置 100 组冻结策略测试任务，每组均初始化几何尺寸、径向偏差、控制参数及精度要求四类条件。下面的任务表为本次预生成的测试输入，不是已经执行的仿真记录；随机数生成器为 NumPy default_rng，种子为 20260831。网络权重、场景版本和测试代码应在执行前冻结，并采用不与训练集共用的种子集合。

几何条件从 16～21 mm 的六个轴径中等概率选取，孔径固定为 22 mm；偏差半径在 10～25 mm 内均匀抽样，方位角在 0～360°内均匀抽样。位置与姿态刚度倍率分别在 0.75～1.25 和 0.85～1.15 内抽样，阻尼和虚拟质量倍率均在 0.80～1.20 内抽样。精度要求 τ_req 从 0.35、0.50 和 1.00 mm 中独立抽样。

为兼顾配合几何，设计中的有效阈值取 $\tau_{eff}=\min(\tau_{req}, 0.75c)$，其中 c 为实际单边间隙。独立抽样的 τ_{req} 与受几何约束的 τ_{eff} 应分别保存。此规则属于拟执行测试方案，与现有程序 clip(0.75c，0.35，1.20)的判据不同，运行前需明确实施，不能直接用旧日志填充新测试表。

表 2-6　100 组独立装配测试的四类初始化设计

因素类别	随机化定义	实施状态
几何尺寸	轴径六档等概率；孔径 22 mm 固定	沿用既有参数接口，核对实际缩放
初始位置误差	半径 10～25 mm；角度 0～360°	需记录实际预定位偏差
控制参数	Kp 平移/转动、Kd、Md 四个倍率	沿用既有随机化接口
精度要求	$\tau_req \in \{0.35, 0.50, 1.00\}$ mm	独立精度要求；$\tau_eff = \min(\tau_req, 0.75c)$

测试时应使用完整精度的采样参数，记录预定位后的实际偏差、几何缩放状态、回合时间戳、峰值接触力、最终误差与终止原因。下面表格为便于人工查看进行四舍五入；若以表格数值手动执行，则应另存实际使用值，不宣称与全精度随机序列完全一致。各组不得因失败而删除或反复重采样。

表 2-7　100 组随机初始化任务（预生成方案，全部未执行）

编号	轴径 mm	偏差 ρ mm	角度 °	Kp 倍率 位置/姿态	倍率 Kd/Md	精度 mm 要求/有效	结果
001	18	19.65	326.5	1.17/1.00	1.19/1.09	0.35/0.350	待测
002	20	15.18	147.8	1.05/0.94	1.20/0.83	0.50/0.500	待测
003	19	14.89	43.6	0.94/0.93	0.86/1.09	1.00/1.000	待测
004	20	15.60	211.0	0.96/1.05	0.85/1.03	1.00/0.750	待测
005	19	11.65	4.1	1.06/0.96	1.09/0.81	0.50/0.500	待测
006	21	16.51	300.4	1.09/1.06	1.10/1.10	0.50/0.375	待测
007	17	24.40	180.9	0.97/0.95	0.82/0.97	1.00/1.000	待测
008	20	11.66	208.7	1.04/1.09	0.94/1.15	0.35/0.350	待测
009	16	16.92	299.4	0.90/1.05	1.01/0.82	0.50/0.500	待测
010	21	22.06	0.4	1.23/1.12	0.99/1.18	0.50/0.375	待测
011	21	15.52	46.8	1.23/1.05	1.07/1.20	1.00/0.375	待测
012	21	23.89	65.8	1.04/1.00	1.20/0.99	0.50/0.375	待测
013	17	20.07	299.3	1.21/0.92	0.97/1.14	0.50/0.500	待测

编号	轴径 mm	偏差 ρ mm	角度 °	Kp 倍率 位置/姿态	倍率 Kd/Md	精度 mm 要求/有效	结果
014	17	15.75	326.6	0.96/1.08	0.94/0.86	1.00/1.000	待测
015	20	10.47	351.5	1.17/1.09	1.20/1.09	1.00/0.750	待测
016	20	16.59	135.4	0.75/0.91	0.89/1.05	0.35/0.350	待测
017	16	19.07	302.9	1.19/0.88	1.12/1.08	0.35/0.350	待测
018	18	22.07	158.6	0.89/0.93	1.00/0.87	0.50/0.500	待测
019	19	12.07	203.8	1.24/1.08	0.91/0.83	0.50/0.500	待测
020	16	17.46	337.6	1.18/1.04	1.13/0.82	0.35/0.350	待测
021	20	18.79	262.5	0.93/0.93	1.09/0.97	0.35/0.350	待测
022	17	17.69	222.5	0.79/1.11	0.97/1.05	0.50/0.500	待测
023	18	23.82	110.7	1.01/0.97	1.02/1.16	1.00/1.000	待测
024	16	14.03	268.4	1.16/0.89	0.83/0.84	0.35/0.350	待测
025	21	22.34	14.6	1.19/0.89	1.02/0.84	0.35/0.350	待测
026	17	19.93	334.9	0.75/0.99	0.99/0.90	0.35/0.350	待测
027	20	17.73	331.4	1.20/1.01	1.19/0.94	1.00/0.750	待测
028	21	14.55	49.6	1.15/0.92	0.90/0.80	1.00/0.375	待测
029	17	20.47	144.4	0.92/1.08	1.12/0.95	1.00/1.000	待测
030	18	10.26	277.7	1.09/1.08	0.95/0.99	1.00/1.000	待测
031	19	21.08	201.8	1.12/1.08	0.81/1.00	0.35/0.350	待测
032	21	16.63	265.2	1.09/0.99	1.14/1.18	0.35/0.350	待测
033	16	16.36	344.6	1.00/1.12	1.10/0.84	0.35/0.350	待测
034	19	10.97	343.9	1.21/0.98	1.10/0.97	0.35/0.350	待测
035	21	16.06	315.2	1.03/1.03	1.18/0.85	0.35/0.350	待测
036	20	10.47	104.1	0.90/1.14	1.05/1.15	0.35/0.350	待测
037	21	24.89	328.9	1.07/0.91	1.18/1.18	0.35/0.350	待测
038	17	22.80	86.4	0.90/1.12	0.83/1.05	0.50/0.500	待测
039	21	17.64	302.8	0.87/0.98	1.07/1.11	0.35/0.350	待测
040	20	20.60	119.9	0.96/1.00	0.95/0.88	1.00/0.750	待测
041	18	15.21	57.7	0.77/0.96	0.81/1.19	0.35/0.350	待测
042	16	23.70	246.2	0.82/1.14	0.97/0.95	1.00/1.000	待测
043	21	14.25	287.7	1.12/1.12	0.84/1.16	1.00/0.375	待测

编号	轴径 mm	偏差 ρ mm	角度 °	Kp 倍率 位置/姿态	倍率 Kd/Md	精度 mm 要求/有效	结果
044	19	17.07	355.9	1.12/0.98	1.08/0.85	0.35/0.350	待测
045	19	22.00	49.3	1.21/1.07	1.19/0.94	1.00/1.000	待测
046	17	18.18	31.2	1.18/0.89	1.18/1.09	1.00/1.000	待测
047	20	19.42	351.4	0.94/1.07	0.86/0.83	1.00/0.750	待测
048	16	16.95	353.9	1.09/1.09	1.15/0.96	0.50/0.500	待测
049	19	17.59	188.0	0.93/0.95	0.84/1.16	1.00/1.000	待测
050	18	18.63	240.2	1.04/1.03	0.88/0.91	1.00/1.000	待测
051	20	13.60	2.1	1.11/0.88	1.18/1.10	1.00/0.750	待测
052	16	10.23	342.3	0.90/1.10	1.07/0.81	1.00/1.000	待测
053	20	22.93	97.0	1.01/1.13	1.14/1.16	0.35/0.350	待测
054	21	13.06	203.5	0.98/1.02	1.10/0.98	1.00/0.375	待测
055	16	10.41	258.6	1.23/1.07	0.97/1.01	0.50/0.500	待测
056	21	18.31	228.4	0.99/1.10	1.04/1.03	0.50/0.375	待测
057	21	16.41	320.2	1.23/0.91	0.86/0.90	0.50/0.375	待测
058	17	13.94	62.1	1.03/1.03	1.06/1.12	1.00/1.000	待测
059	20	17.08	37.0	0.99/0.94	0.93/0.88	0.50/0.500	待测
060	17	10.86	291.0	1.22/0.98	1.02/0.99	0.50/0.500	待测
061	19	17.89	88.8	1.09/1.07	1.13/1.15	1.00/1.000	待测
062	17	20.91	131.8	0.84/1.00	1.08/1.19	0.50/0.500	待测
063	19	22.26	167.0	0.77/0.93	1.11/1.18	0.50/0.500	待测
064	17	21.65	220.6	0.81/1.01	1.17/0.90	0.35/0.350	待测
065	20	17.49	197.4	0.83/1.10	1.09/1.14	0.50/0.500	待测
066	18	10.20	104.0	0.91/1.12	0.94/0.82	1.00/1.000	待测
067	21	19.89	76.2	0.89/0.97	1.12/0.99	0.50/0.375	待测
068	20	20.65	34.5	0.77/1.12	1.04/0.88	0.50/0.500	待测
069	21	15.07	45.6	0.76/1.13	0.90/1.18	0.35/0.350	待测
070	19	15.81	150.9	0.83/0.85	1.14/1.11	0.35/0.350	待测
071	17	18.80	313.6	1.06/0.97	1.15/1.12	0.50/0.500	待测
072	20	21.00	299.1	1.00/1.06	0.85/0.81	0.35/0.350	待测
073	20	24.76	146.3	0.98/1.10	0.87/0.93	0.35/0.350	待测

编号	轴径 mm	偏差 ρ mm	角度 °	Kp 倍率 位置/姿态	倍率 Kd/Md	精度 mm 要求/有效	结果
074	16	18.00	224.1	0.93/1.08	0.90/0.93	0.50/0.500	待测
075	20	24.13	134.7	0.95/0.87	1.06/1.06	0.35/0.350	待测
076	17	11.38	3.4	1.19/0.96	1.19/1.13	1.00/1.000	待测
077	17	21.98	121.6	0.88/1.14	1.01/0.85	1.00/1.000	待测
078	21	17.62	280.2	0.94/0.91	1.16/1.11	1.00/0.375	待测
079	19	12.33	138.1	1.03/0.93	0.87/1.14	1.00/1.000	待测
080	20	11.98	183.5	0.85/0.99	0.85/0.93	0.35/0.350	待测
081	16	14.98	289.4	0.95/0.95	1.17/1.11	0.50/0.500	待测
082	17	12.48	153.2	1.14/0.88	0.88/1.12	0.50/0.500	待测
083	19	14.71	98.4	1.08/1.06	1.11/1.07	0.35/0.350	待测
084	21	20.93	240.2	1.08/1.11	0.81/0.99	0.35/0.350	待测
085	18	15.84	263.2	0.98/1.14	1.04/0.95	1.00/1.000	待测
086	19	10.35	207.9	0.86/1.13	0.92/1.14	1.00/1.000	待测
087	16	11.36	271.7	1.22/1.10	1.14/0.90	0.50/0.500	待测
088	18	23.81	29.6	1.14/0.90	0.92/1.17	0.50/0.500	待测
089	19	18.77	0.5	1.11/0.90	0.84/0.97	1.00/1.000	待测
090	16	23.90	196.2	1.19/1.00	0.91/0.89	1.00/1.000	待测
091	17	23.39	251.4	0.80/0.92	0.95/0.81	0.35/0.350	待测
092	17	22.22	345.8	0.88/0.85	1.03/1.01	1.00/1.000	待测
093	19	15.26	104.3	0.81/1.00	1.00/0.95	0.50/0.500	待测
094	20	10.51	266.7	1.09/0.86	0.94/0.90	1.00/0.750	待测
095	21	24.84	247.9	1.22/1.09	0.83/0.86	0.50/0.375	待测
096	21	11.82	103.8	1.09/1.04	1.02/1.06	1.00/0.375	待测
097	19	15.31	307.4	1.08/1.14	1.18/0.82	0.50/0.500	待测
098	20	21.31	89.7	0.87/1.12	1.02/0.82	0.35/0.350	待测
099	18	13.50	277.5	0.98/0.90	0.90/0.98	1.00/1.000	待测
100	21	13.80	258.8	0.87/1.13	1.00/0.95	1.00/0.375	待测

2.3.4.2 成功率与结果统计口径

每组任务在规定步数内同时满足有效径向阈值和深度条件，且没有触发预先规定的安全终止，方可计为成功。若某次仿真因通信失败、模型加载错误等未有效执行，应单列异常并保留原始任务编号；未经有效执行的任务不应悄悄计为成功或从分母中删除。

$$成功率 = \frac{N_{success}}{N_{valid}} \times 100\%$$

$$平均成功用时 = \frac{成功任务实际仿真用时之和}{N_{success}}$$

项目技术指标规定仿真场景任务成功率应大于 90%。当前尚未完成冻结策略下的独立 100 组仿真测试，因此表中实测指标保持待测。只有当 100 组任务全部有效执行且成功数不少于 91 组时，观察成功率才满足“大于 90%”的项目指标；有限样本结果仍不构成对任意场景成功概率的保证。若出现零成功，平均成功用时应记为不适用，不能填写为零秒。

表 2-8　独立 100 组装配测试结果登记表

统计项目	填写规则	本次状态
计划任务数量	100 组	已列出输入方案
有效执行数量	以有效运行记录计	未执行
成功数量	同时满足几何与安全条件	待测
总体成功率	成功数/有效组数×100%	待测
项目成功率指标	＞90%（尚未验证）	不作为已取得结果
平均/中位成功用时	仅对成功组使用仿真时间戳	待测
最终径向误差	记录均值、中位数与分位数	待测
接触峰值力/力矩	由连续记录计算	待测
失败原因分布	超时、越界、过深、限力等	待测

统计项目	填写规则	本次状态
异常运行数量	通信/模型异常单独登记	待测

正式结论应由测试完成后的实际记录生成，至少给出成功数量、有效总数、成功率、时间分布、误差分布和失败原因，并对不同配合尺寸与初始偏差作分组分析。检验残差方法的贡献还需设置同一100 组任务上的启发式基线、当前 DQN 融合方法及显式残差方案对照。当前报告完成了理论与方法描述、现有训练日志分析及待执行测试设计，不将这些工作表述为已经完成高成功率装配验证。

本章参考文献与数据来源

[1] Sutton R S, Barto A G. Reinforcement Learning: An Introduction. 2nd ed. MIT Press, 2018. https://mitpress.mit.edu/9780262039246/reinforcement-learning/

[2] Mnih V, et al. Human-level control through deep reinforcement learning. Nature, 2015, 518: 529–533. https://doi.org/10.1038/nature14236

[3] Johannink T, et al. Residual Reinforcement Learning for Robot Control. arXiv:1812.03201. https://arxiv.org/abs/1812.03201

[4] 华灵蕙. 基于强化学习的机械臂高精度装配技术[D]. 哈尔滨工业大学, 2025.

[5] Haarnoja T, Zhou A, Abbeel P, Levine S. Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor[C]//Proceedings of the 35th International Conference on Machine Learning. PMLR, 2018, 80: 1861–1870. https://proceedings.mlr.press/v80/haarnoja18b.html

代码依据：MulBotAsm/trainer/dqn_train3.py；envs/DSAE1.py；envs/DualSpaceArmController.py；algorithm/dqn_model.py。本章参数按 2026 年 8 月 31 日读取的版本核对；未修改项目代码或启动仿真。

A 组日志：trainer/training_logs_10actions_adaptive_insert_30to5_200steps_800episodes；B 组日志：trainer/training_logs_10actions_random_kpkdmd_peg16to21_hole22_200steps_500episode

s。曲线与统计依据各目录的 ep_rewards.npy、successList.npy、random_offsets.json、fail_reasons.json 快照。

输入计划：表 2-7 的 100 组参数由 NumPy default_rng(20260831)生成；结果栏全部待测，不能作为成功率、接触力或完成时间的实验凭证。